

CF_FSNN — Report FPGA (Fase A)

Profilo di idoneità FPGA (Zynq-7020 / PYNQ-Z1) dei 4 champion, pre-silicio — 45 figure a dati reali su 10 sezioni

Terzo membro del trio v3 · gemelli: HOW_IT_WORKS_v3 (teoria) · VALIDATION_REPORT_v3 (risultati)

Branch EventProp_Study · Fase A "software_now": profilazione SW pre-silicio (le Fasi B/C = HDL/board)

Sorgente figure: scripts/fpga_figures.py (librerie weight/state/latency/seu/io) · risultati: results/evaluate/FPGA/

In una pagina: cos'è e come si legge

Questo report è la valutazione di idoneità FPGA dei 4 champion (2 BPTT: Raffaello, Leonardo; 2 EventProp: Donatello, Michelangelo) PRIMA di toccare il silicio. È la Fase A "software_now": ogni numero ρ è calcolato dai tensori e dal forward reali della rete (non da un datasheet), tramite le 5 librerie di profilazione. Le figure marcate $\square/\square$ (datapath HDL, area, termico) sono STIME di progetto, da confermare solo con la sintesi Vivado e la misura su board (Fasi B/C).

Come si legge: la sezione 0 è il cruscotto (radar + tabella di numeri reali) con il verdetto di deploy; le sezioni 1-8 lo fondano dimensione per dimensione (pesi po2, fixed-point, spiking, energia, timing, risorse, SEU, I/O); la 9 è termica (stime). Contesto e teoria della rete: HOW_IT_WORKS_v3 §16. I risultati di validazione della guida (sicurezza, traffico, accuratezza): VALIDATION_REPORT_v3 (di cui §9 è il sommario FPGA che rimanda qui).

Nota. Due verità che attraversano tutto il report (coerenti col fix del bug n_ticks): (1) i champion sparano ~13-21%, NON sono iper-sparsi; (2) il vantaggio energetico (~5.11-8.38 $\times$) viene dal costo $AC < MAC$ e da 0 DSP, NON dalla sparsità. L'edge FPGA degli EventProp è $\rho < 1$ (contrattivo) + 0 neuroni morti.

Champion	Metodo	Checkpoint	$\rho(U \cdot V)$	spike %	energia $\times$	footprint
Raffaello	BPTT	R33_C2_A1_T12_fix	2.99	13.9%	8.38 $\times$	400 B
Leonardo	BPTT	LS3_PEAK_R0_launch_d03	1.16	12.6%	8.38 $\times$	400 B
Donatello	EventProp	PE_t05_gp0002	0.05	20.8%	5.11 $\times$	656 B
Michelangelo	EventProp	A_lr1e2_t06_r16	0.39	15.5%	5.11 $\times$	656 B

0. Readiness: la scorecard di idoneità FPGA

La sezione apre con il cruscotto: un radar per champion e una tabella di numeri reali. Le sei dimensioni della readiness sono TUTTE metriche misurate (niente colonne costanti o etichette fuorvianti): $\rho < 1$ (contrattività della ricorrenza), Fix-pt (robustezza alla quantizzazione po2), Sparsità (firing), Energia (vantaggio $AC < MAC$), Timing (margine sul deadline), SEU (robustezza al bit-flip). Il radar dà la forma d'insieme; la tabella deploy_verdict dà i valori esatti confrontabili, colorati per rango.


Il candidato al deploy è Donatello (EventProp): ρ minimo (0.051), errore di quantizzazione po2 il più basso, 0 neuroni morti. Il rovescio onesto: spara di più (20.8%) e ha quindi il vantaggio energetico più BASSO (5.11 $\times$). Leonardo (BPTT) è il più fragile (Fix-pt e SEU bassi). L'edge FPGA di EventProp è $\rho < 1$ + 0 morti, NON la sparsità o l'energia.

Deploy Verdict

champion	$\rho(U \cdot V)$	spike %	quant-err %	energia $\times$	util %	SEU worst	footprint B
Raffaello	2.99	13.9	4.8	15.2 $\times$	0.12	0.007	400
Leonardo	1.16	12.6	15.5	15.4 $\times$	0.12	0.042	400
Donatello	0.05	20.8	1.9	8.6 $\times$	0.17	0.010	656
Michelangelo	0.39	15.5	6.2	9.0 $\times$	0.17	0.018	656

I NUMERI REALI dietro il radar, una colonna per asse + footprint. Colorazione per RANGO (verde = migliore dei 4 su quella metrica, nessuna soglia arbitraria). Candidato deploy: Donatello (ρ minimo 0.05, quant robusto).

Readiness Radar




Radar di FPGA-readiness per champion (small-multiples). Ogni asse 0-1 con ANCORA esplicita fra parentesi (1 = ideale FPGA): $p < 1$ (contrattivo), Fix-pt (quant po2 senza errore), Sparsità (poco firing), Energia ($\geq 15\times$ vs ANN), Timing (util ≈ 0), SEU (0 bit critici). I valori numerici reali sono nella tabella successiva.

1. Pesi Power-of-Two: il moltiplicatore che sparisce

Il cuore del co-design è la quantizzazione po2 (schema e razionale in HOW_IT_WORKS_v3 §15). Qui il lato hardware misurato: il moltiplicatore diventa un bit-shift $\rightarrow 0$ DSP; e l'istogramma po2_alphabet mostra la SPARSITÀ DEI PESI (sinapsi a valore 0 = eliminabili dal connettoma) — da non confondere coi neuroni morti (attività, §3): sono sinapsi che semplicemente non esistono in hardware.


Il footprint dei pesi è di 400-656 byte per champion (rank-8 vs rank-16): trascurabile vs la BRAM (§6). Il raggio spettrale $\rho(U \cdot V)$ (definizione in HOW §11) separa nettamente EventProp (contrattivo, $\rho < 1$) da BPTT (espansivo, $\rho > 1$): è il discriminante che rende gli EventProp sicuri in aritmetica a virgola fissa.

PO2 Alphabet




Alfabeto po2 dei pesi (13 valori sign- 2^k) per champion. "pesi a 0 = sinapsi eliminabili" è la potatura strutturale del connettoma (sinapsi a peso 0), NON neuroni morti. Il moltiplicatore è UNO di 13 valori → barrel-shifter, 0 DSP.

PO2 Exponent Range




Range di esponente po2 usato per matrice, per champion → numero di bit di esponente necessari.

Resource Occupancy




Occupazione stimata del budget Zynq-7020 (LUT/FF/BRAM/DSP) per champion. BRAM reale (footprint pesi); LUT/FF stima; DSP = 0 (po2 → shift-add).

Sparsity Mask



% pesi a zero per matrice (fc / rec_U / rec_V / out), per champion: la sparsità strutturale del connettoma → sinapsi eliminabili in hardware.

Spectral Recurrence




Raggio spettrale $\rho(U \cdot V)$: pieno = po2, vuoto = float. $\rho < 1$ (EventProp) = loop contrattivo, sicuro in fixed-point; $\rho > 1$ (BPTT) = espansivo (rischio overflow). È IL discriminante di stabilità hardware.

2. Fixed-point: formato Qm.n e robustezza alla quantizzazione

Ogni registro interno (potenziale, fatica, corrente ricorrente, uscita LI) riceve un formato Qm.n con gli interi dal RANGE MISURATO e i frazionari dal budget di bit. La rete tollera una quantizzazione aggressiva: l'errore di identificazione resta basso fino a pochi bit. Il punto fragile è la quantizzazione po2 di deploy: Leonardo ha l'errore po2 più alto (quant-err ~15-16%), gli altri restano bassi (Donatello ~2%).


Il caveat onesto: la curva quant_vs_bits è pienamente valida solo con re-training QAT; qui è una stima post-hoc. Il leak di membrana (bit-shift, cfr. HOW §15) con troppo pochi frac_bits manda il potenziale in sotto-flusso e lo blocca — un vincolo reale sul numero minimo di bit frazionari (figura leak_decay). Gli state-range sono catturati solo per i baseline (limite del profiler sulla variante EventProp, che non fa un forward per-step).

Bit Allocation




Formato Qm.n per ogni stato interno (segno + interi dal RANGE MISURATO + frazionari). Solo baseline (gli stati non sono catturati per la variante EventProp — limite del profiler).

Chattering




Accelerazione closed-loop: float (liscia) vs parametri quantizzati a 2 bit (nervosa), per champion — stress test dell'instabilità da quantizzazione.

Leak Decay




Il leak di membrana è un bit-shift ($V \cdot 7/8$): con pochi frac_bits il potenziale va in sotto-flusso e resta BLOCCATO; con 8 bit $\sim$ float.

Per Param Fragility




Quale dei 5 parametri cede di più sotto quantizzazione po2, per champion.

Quant vs Bits



Errore di identificazione vs bit-width dei pesi, per champion (linea piena = fixed Qm.n, tratteggio = po2 di deploy). La rete tollera pochi bit; Leonardo ha l'errore po2 più alto.

State Ranges




Range dinamico min..max dei registri interni fixed-point (| rosso = p0.1/p99.9): il range fissa gli int_bits.

3. Dinamica spiking: sparsità reale e salute della rete

La dinamica spiking sfata un equivoco: i champion sparano ~13-21% dei neuroni per tick, NON sono iper-sparsi (~1-2%). Il raster e la mappa di attività lo mostrano cross-champion. Questo è il dato corretto dopo il fix del bug n_ticks: il valore ~1.5% era un artefatto di calcolo (doppia divisione per n_ticks). NB: questi spike-rate (profiler op-count, finestra launch) differiscono di ~1-2 punti da VALIDATION §9.2 (evaluate a 6-tier; es. Donatello 20.8% qui vs 19.0% là) — stessa realtà, finestre/metodo di misura diversi.


Il picco di spike simultanei per tick dimensiona l'albero di accumulo (AC) in hardware; l'ISI minimo dà il worst-case back-to-back. La salute della rete è il vero discriminante: gli EventProp hanno 0 neuroni morti, i BPTT ~31% — la ricorrenza contrattiva e il gradiente esatto tengono viva l'intera popolazione.

Activity Map




Mappa di firing per neurone hidden, per champion: hotspot vs neuroni morti (rate 0).

Dead Saturated




Neuroni morti (rate 0) e saturi (rate ~1) per champion: gli EventProp hanno 0 morti, i BPTT ~31% — la salute della rete è un vantaggio del gradiente esatto.

ISI Dist




Distribuzione degli inter-spike-interval, per champion: l'ISI minimo dà il worst-case back-to-back.

Raster



Raster degli spike ordinato per firing-rate, tutti i champion (% attivi/tick fra parentesi). I champion sparano ~13-19% — NON sono iper-sparsi.

Sparsity Per Tick



Spike concorrenti per tick, per champion: il MAX simultaneo fissa la larghezza dell'albero di accumulo (AC).


4. Energia: il vantaggio $AC < MAC$ (e da dove NON viene)

Il vantaggio energetico vs una ANN densa è $\sim 5.11-8.38\times$ (worst-case; fino a $\sim 15\times$ nel caso tipico). NON viene dalla sparsità: le SynOps eguagliano o superano i MAC dell'ANN. Viene dal minor costo unitario di un accumulo (AC) rispetto a una moltiplicazione-accumulo (MAC), amplificato su FPGA dai pesi po2 (AC = shift+add) e da 0 DSP.

Conseguenza contro-intuitiva: Donatello, il più contrattivo, spara di più ($\sim 20.8\%$) e ha quindi il vantaggio energetico più basso ($\sim 5.11\times$). Il breakdown mostra dove si spendono i pJ (la ricorrenza rec_V/rec_U domina nei rank-16); il grafico `energy_vs_rate` marca il rate operativo reale, ben dentro il regime denso, non quello iper-sparso.


Coerenza col gemello: VALIDATION_REPORT_v3 §9.2 riporta una stima più grossolana ($\sim 4.77-6.01\times$) dall'evaluate a 6-tier; qui il modello op-count distingue il worst-case ($\sim 5.11-8.38\times$) dal tipico ($\sim 9-15\times$). Stesso ordine di grandezza — e ben lontano dai 22-30 $\times$ pre-fix del bug `n_ticks`.

Energy Breakdown




Dove si spendono i pJ per champion (fc / rec_V / rec_U / out / non-sinaptiche).

Energy vs ANN




Energia per inferenza: SNN tipico (sparso) vs SNN worst-case (denso) vs ANN densa (MAC), per champion, con il vantaggio $\times$. Il guadagno viene dal costo $AC < MAC$ (0 DSP), NON dalla sparsità.

Energy vs Rate



Energia vs spike-rate: i pallini marcano il rate operativo reale (~13-19%) — i champion NON sono nel regime iper-sparso.

Synops Split




Parte statica (input, sempre-on) vs dinamica (spike-driven) delle SynOps per champion → dove conviene il clock-gating.

5. Timing / WCET: margine sul deadline e jitter zero

Il conteggio operazioni per tick è l'input del WCET e distingue rank-8 (baseline) da rank-16 (EventProp) sui rami ricorrenti. Su qualunque delle 4 architetture HW considerate, il tempo di inferenza è di pochi μ s contro un deadline di controllo di 100 ms: il margine è enorme (utilizzo $\sim 0.1\%$). Il budget di 100 ms è la leva che permette di ottimizzare per AREA (CORDIC iterativo, $DSP \approx 0$) invece che per velocità.


Proprietà preziosa per un sistema safety: WCET == BCET. Il numero di operazioni è costante a ogni spike-rate (worst-case), quindi il jitter di calcolo è nullo — un vantaggio di determinismo temporale rispetto a un'esecuzione data-dependent.

Decode Criticalpath




STIMA del datapath del decode ACC-IIDM (sqrt/div/sigmoid/tanh) in PL: CORDIC iterativo (shift-add, $DSP \approx 0$) sul budget di 100 ms.

Jitter Proof




WCET == BCET: il numero di operazioni è costante a ogni spike-rate → jitter di calcolo = 0 (esemplare: Donatello).

Latency Margin




Tempo di inferenza vs deadline di controllo 100 ms, per champion: margine enorme (util ~0.1%).

Op Count



Conteggio operazioni per tick (input del WCET), per champion: si vede la differenza rank-8 (baseline) vs rank-16 (EventProp) sui rami ricorrenti.

WCET Cycles




Cicli e μ s per inferenza secondo 4 architetture HW (esemplare: Donatello; datapath simile fra champion).

6. Risorse e DSE: 0 DSP, <1% BRAM

Il conto delle risorse è netto: 0 DSP (ogni operazione è AC o shift-add, nessun moltiplicatore) e <1 BRAM su 140 per la memoria pesi (<1% del budget). Lo spazio di design (DSE) mostra il trade-off area↔latenza al variare del parallelismo: con 100 ms di budget conviene la variante seriale, minima in area.


Le stime di area LUT/FF (area_model) sono pre-sintesi e vanno confermate in Fase B (Vivado); la BRAM e il conteggio operazioni sono invece reali.

Area Model




STIMA dell'area (LUT/FF) al variare del parallelismo — da confermare in sintesi (Fase B).

Bram Dimensioning




Memoria pesi per champion: <1 BRAM su 140 (<1% del budget).

DSE Pareto



Trade-off area↔latenza per grado di parallelismo, per champion (latenza reale, area STIMA).

Op By Celltype




Operazioni per tipo di cella (AC spike-driven vs shift-add po2) per champion: nessun moltiplicatore → 0 DSP.

7. SEU / ISO 26262: robustezza ai bit-flip e TMR mirato

La robustezza ai Single Event Upset (un neutrone atmosferico che inverte un bit nella memoria pesi) è profilata via fault-injection software: si decodifica il peso po2, si inverte un bit, si riesegue l'identificazione. La mappa di sensibilità e la criticità per bit dicono quali bit dominano il rischio (l'esponente-MSB e il segno) → ECC mirata invece che totale.

La curva degrade_vs_flips mostra 0 collisioni fino a 8 bit-flip accumulati per tutti e 4 i champion → il periodo di scrubbing può essere rilassato. Leonardo è il più fragile ai SEU. Il confronto hidden vs readout indica dove concentrare il TMR (il readout, più critico). Le stime di overhead TMR sono di progetto (da validare in sintesi).

Bit Criticality



Quali bit (esponente-LSB/mid/MSB, segno) dominano il rischio SEU, per champion → ECC mirata.

Concept — Cosa Sono I Bit-flip


07 – SEU (Single Event Upset)

Un neutrone atmosferico può invertire UN bit nella memoria dei pesi ($0 \leftrightarrow 1$). Il peso $po2$ corrotto cambia segno/esponente $\rightarrow$ i 5 param cambiano $\rightarrow$ l'accel comandata cambia $\rightarrow$ possibile collisione.

Simulato ORA: seu_inject decodifica peso $\rightarrow$ 4bit, inverte un bit, riscrive il valore guasto nel tensore e rilancia identify/eval_safety. Reale, no HW.


Concetto: un Single Event Upset (SEU) inverte UN bit nella memoria dei pesi $po2 \rightarrow$ i 5 parametri cambiano $\rightarrow$ l'accelerazione cambia $\rightarrow$ possibile collisione. Simulato via seu_inject (reale, no HW).

Degrade vs Flips




Collisione closed-loop vs numero di bit-flip accumulati, per champion: 0 collisioni fino a 8 flip (i 4 champion sovrapposti a 0) $\rightarrow$ periodo di scrubbing.

Hidden vs Readout




Criticità SEU media hidden (fc/rec) vs readout (out), per champion → dove concentrare il TMR (il readout è più critico?).

Perparam Shift




Spostamento per-parametro sotto SEU, per champion: quale parametro è più esposto.

Sensitivity Map



Δ errore-di-identificazione invertendo 1 bit di un peso (heatmap), per champion: quali bit/pesi sono critici.

TMR Overhead



STIMA del costo del Triple Modular Redundancy (TMR) selettivo sul readout vs protezione totale.


8. I/O e Hardware-in-the-Loop: canale V2X e code

Il lato I/O modella il canale V2X e le code di ingresso. La superficie AoI (Age-of-Information) dà l'età massima tollerabile di un CAM prima che la guida diventi insicura, sul piano $\text{gap} \times \Delta v$. Il messaggio chiave, coerente col report di validazione: la robustezza alla perdita di pacchetti è dell'HANDLER

"hold-last", NON della rete — senza handler la collisione esplode.


Il dimensionamento della coda RX (M/M/1/K) dà il buffer minimo anti-burst dei messaggi; la curva PDR mostra il "ginocchio" oltre cui la perdita pacchetti diventa pericolosa. Queste figure combinano dati reali (comportamento della rete) e stime di modello (coda).

Aol Dist




Distribuzione dell'Age-of-Information sotto perdita/ritardo dei pacchetti V2X.

Aol Max Surface




Età MAX tollerabile del CAM V2X (AoI) sul piano $\text{gap} \times \Delta v$ oltre cui la guida è insicura (verde = tollera di più; esemplare: Donatello).

Holdmode




Confronto degli handler di pacchetti mancanti (hold-last / dead-reckon / blind): la robustezza V2X è dell'HANDLER, non della rete.

PDR Latency Knee



Curva collisione vs Packet Delivery Ratio / latenza V2X: il "ginocchio" oltre cui perdita e ritardo dei pacchetti CAM diventano pericolosi per la guida.

Queue Overflow




Probabilità di drop su burst vs profondità della coda RX (M/M/1/K, STIMA): buffer minimo anti-burst dei messaggi CAM.

9. Termico: derating (stime pre-sintesi)


La sezione termica è interamente di STIMA (□): il derating di Fmax con la temperatura di giunzione e il budget termico sullo Zynq-7020. Servono a impostare i margini, ma i numeri reali arriveranno solo dalla sintesi e dalla misura su board (Fasi B/C). Sono inclusi marcati come stime, non come risultati.

Derating Tj Fmax



STIMA: Fmax vs temperatura di giunzione Tj — a caldo il clock scende, resta headroom sul target a 100 °C?

Thermal Budget



STIMA del budget termico (potenza vs dissipazione) sullo Zynq-7020.

Verdetto e prossimi passi

Sul profilo pre-silicio il candidato al deploy è Donatello (EventProp): ricorrenza contrattiva ($\rho \approx 0.051$ → fixed-point sicuro), quantizzazione po2 robusta, 0 neuroni morti, timing e risorse soddisfatti con margine enorme (0 DSP, <1% BRAM, μs vs 100 ms). Il rovescio onesto: essendo il più attivo (~20.8% firing) ha il vantaggio energetico più basso (~5.11×); e Leonardo resta il più fragile su quantizzazione e SEU.

Nota. Cosa è REALE e cosa è STIMA. Reali (□): readiness, pesi po2, spiking, energia (modello Horowitz), op-count/timing, footprint/BRAM, SEU (fault-injection SW). Stime (□/□): area LUT/FF, datapath del decode, overhead TMR, coda RX, termico. Le stime si confermano solo in Fase B (sintesi Vivado → LUT/FF/DSP/Fmax reali) e Fase C (FPGA-in-the-Loop → potenza/latenza/SEU su silicio).

Riproducibilità e mappa dei file

Cosa	Dove
Figure e CSV FPGA (45 figure, 10 sez.)	results/evaluate/FPGA/
Generatore figure (dati reali)	scripts/fpga_figures.py
Librerie Fase A	utils/{weight_profiler,state_profiler,latency_model,seu_inject,io_hil}.py
Notebook FPGA-evaluate	Eval_FPGA.ipynb
Verifica manifest post-run	scripts/verify_fpga_eval.py
Questo report (generatore)	scripts/build_fpga_report.py
Design e framework della valutazione	document/FPGA_EVALUATE_DESIGN.md / FPGA_EVALUATION_FRAMEWORK.md
Teoria della rete (gemello)	document/HOW_IT_WORKS_v3.md
Risultati di validazione (gemello)	document/VALIDATION_REPORT_v3.md (§9 = sommario FPGA)