

Stato dell'Arte dei Modelli di Car-Following e Controllo del Traffico in Ambienti V2X: Dai Paradigmi Fisici all'Accelerazione Hardware AI

1. Introduzione e Fondamenti della Modellazione Microscopica del Flusso di Traffico

La modellazione del flusso di traffico rappresenta uno strumento analitico di importanza critica per la comprensione, la previsione e la valutazione dell'efficienza e della sicurezza dei sistemi di trasporto. All'interno di questo vasto dominio, la simulazione microscopica si distingue per la sua capacità di analizzare le dinamiche dei veicoli a livello individuale, riproducendo matematicamente le interazioni continue tra unità adiacenti.¹ Il nucleo centrale di qualsiasi simulatore microscopico (come SUMO, VISSIM o PARAMICS) è costituito dal modello di *car-following* (CF), un costrutto algoritmico progettato per descrivere il moto longitudinale di veicoli successivi che procedono all'interno della medesima corsia.³

L'evoluzione storica dei modelli di car-following, le cui radici risalgono agli studi pionieristici condotti da Reuschel nel 1950 e da Pipes nel 1953, ha attraversato decenni di progressi interdisciplinari, assorbendo concetti dall'ingegneria del traffico, dalla cinematica, dalla psicologia cognitiva e, più recentemente, dall'intelligenza artificiale (AI) e dalla teoria del controllo dei sistemi dinamici.¹ L'obiettivo fondamentale di questi modelli è stabilire una mappatura matematica tra gli stimoli ambientali percepiti dal conducente (o dai sensori del veicolo) — tipicamente la distanza relativa (spacing), la velocità del veicolo ospite e la differenza di velocità rispetto al veicolo che lo precede — e una conseguente azione di controllo, che si traduce in un comando di accelerazione o decelerazione.⁷

Con l'imminente transizione verso ecosistemi di trasporto caratterizzati da un'autonomia di livello 4 e 5 e dalla pervasività delle comunicazioni Vehicle-to-Everything (V2X), la validità dei modelli tradizionali è stata messa in discussione.⁸ I veicoli autonomi (AV) e i veicoli connessi e autonomi (CAV) non sono soggetti ai tempi di reazione biologici, all'affaticamento visivo o alle illusioni ottiche che affliggono i conducenti umani, e possiedono capacità di percezione che si estendono oltre la linea di vista (Non-Line-of-Sight, NLOS).¹⁰ Di conseguenza, l'industria e l'accademia stanno assistendo a un radicale cambio di paradigma: dal predominio dei modelli puramente analitici e basati sulla fisica, si sta passando a framework ibridi guidati dai dati, reti neurali informate dalla fisica (PINN) e agenti basati sul Deep Reinforcement Learning (DRL).⁶ Tale transizione algoritmica impone sfide computazionali senza precedenti, rendendo l'utilizzo di acceleratori hardware AI (come GPU, NPU e TPU) non più un'opzione, ma un requisito

stringente per l'esecuzione in tempo reale (real-time inference) a bordo veicolo (Edge Computing).¹³

2. Il Paradigma Cinematico: Il Modello di Newell e le Sue Limitazioni

Nel tentativo di descrivere matematicamente la cinematica del traffico veicolare, il modello semplificato di car-following proposto da G.F. Newell nel 1961 (e successivamente raffinato) ha rappresentato un punto di svolta fondamentale.⁶ Il modello di Newell appartiene alla categoria dei modelli stimolo-risposta ed è stato concepito con l'intento di fornire un framework analitico a basso ordine per descrivere la propagazione delle perturbazioni spaziotemporali all'interno di un flusso di traffico denso e omogeneo.¹⁶

2.1 Formulazione Matematica e Principi Operativi

Il costrutto teorico di Newell si fonda sull'assunto che, in condizioni di traffico congestionato, la traiettoria spaziotemporale di un veicolo inseguitore n sia essenzialmente una traslazione omogenea della traiettoria del veicolo che lo precede, identificato come $n - 1$.¹⁸

Matematicamente, se $x_n(t)$ denota la posizione del veicolo n al tempo t , il modello stabilisce che la traiettoria lineare a tratti del veicolo inseguitore è definita mediante uno spostamento spaziale e un ritardo temporale rispetto al leader.¹⁸

Questi parametri traslazionali corrispondono a due grandezze fisiche specifiche:

1. **Distanza di sicurezza spaziale (d_n):** Rappresenta il gap spaziale che il conducente desidera mantenere in condizioni di congestione, ed è intimamente legato alla distanza minima di arresto o *standstill spacing*.¹⁸
2. **Ritardo temporale (τ_n):** Equivale al tempo di reazione apparente o *time headway* desiderato dal conducente, che governa la latenza con cui l'inseguitore replica le variazioni di velocità del leader.¹⁸

L'ipotesi di base è che i conducenti abbiano la capacità di adattare la loro posizione relativa modificando la propria velocità in modo strettamente controllato, garantendo il mantenimento di uno spazio di sicurezza.⁶ Studi empirici basati su traiettorie videoregistrate hanno convalidato

l'esistenza di tali traslazioni fisse, dimostrando che i parametri τ_n e d_n possono essere descritti attraverso una distribuzione normale bivariata per tenere conto dell'eterogeneità tra i vari conducenti all'interno di una simulazione stocastica.¹⁸ Quando le versioni stocastiche del modello di Newell vengono calibrate su dati individuali, è possibile dimostrare che la spaziatura media in condizioni di congestione equivale alla media aritmetica delle singole spaziature individuali, mentre la velocità di propagazione dell'onda di congestione corrisponde alla media

armonica delle velocità d'onda individuali.¹⁹

2.2 Criticità e Limiti Strutturali del Modello di Newell

Nonostante la sua immensa utilità per la stima macroscopica delle emissioni e per la simulazione rapida delle onde di traffico causate da colli di bottiglia o semafori⁶, il modello di Newell presenta limitazioni stringenti quando applicato alla microsimulazione ad alta fedeltà o al controllo dei veicoli autonomi.

In primo luogo, il modello originario manca di parametri legati alle differenze cognitive intrinseche dei conducenti. Offrendo una rappresentazione altamente semplificata, non è in grado di modellare dinamicamente le asimmetrie del comportamento umano; ad esempio, i conducenti reali reagiscono in modo diverso alle fasi di accelerazione (quando il gap si allarga) rispetto a quelle di decelerazione (quando il gap si restringe bruscamente).¹ In secondo luogo, la natura lineare del modello non riesce a descrivere accuratamente i fenomeni complessi di instabilità di stringa (string instability) senza l'inclusione di termini di correzione esterni o l'integrazione di parametri stocastici multidimensionali.⁶ Infine, il modello presuppone una dipendenza esclusiva dal veicolo immediatamente precedente, ignorando completamente le interazioni multi-veicolo (effetti *backward-looking* o influenze di veicoli situati oltre il diretto leader), che sono invece caratteristiche dominanti negli ambienti V2X.³

3. Oltre Newell: Modelli Fisici e Dinamici Avanzati

Per superare le astrazioni del modello di Newell, l'ingegneria dei trasporti ha sviluppato famiglie di modelli più sofisticati, capaci di descrivere le accelerazioni continue in base alle leggi della dinamica e alle tolleranze psico-fisiche umane. Sebbene nati per descrivere i veicoli a guida umana (HDV), le loro varianti costituiscono tuttora la base logica dei moderni sistemi di Adaptive Cruise Control (ACC).¹⁸

3.1 Il Modello di Sicurezza di Gipps

Proposto nei primi anni '80, il modello di Gipps si fonda su un principio di sicurezza assoluta: un veicolo deve sempre mantenere una distanza e una velocità tali da permettergli di arrestarsi senza collisioni, persino nell'eventualità in cui il veicolo che lo precede applichi improvvisamente la massima decelerazione possibile.¹⁸ A differenza dei modelli cinematici puri, la formulazione di Gipps si basa esplicitamente sulle equazioni newtoniane del moto e introduce parametri fisici realistici: accelerazione massima, velocità desiderata, decelerazione massima del veicolo e tempo di reazione apparente del conducente.¹⁸

Tuttavia, l'implementazione pratica del modello di Gipps soffre di due difetti critici. Innanzitutto, il gap temporale di stato stazionario è matematicamente accoppiato al tempo di reazione del conducente, riducendo i gradi di libertà in fase di calibrazione.¹ Inoltre, il modello originale non fa distinzione tra una decelerazione "confortevole" e una decelerazione di emergenza massima; di conseguenza, il comportamento simulato tende a essere eccessivamente conservativo e a produrre frenate brusche irrealistiche nella normale dinamica di flusso, limitandone l'applicabilità

nello sviluppo di logiche di controllo per il comfort dei passeggeri dei CAV.¹

3.2 L'Optimal Velocity Model (OVM)

Sviluppato da Bando et al. nel 1995 per mitigare le anomalie di accelerazione presenti nel modello di Newell, l'Optimal Velocity Model (OVM) postula che ogni conducente cerchi costantemente di adattare la propria velocità reale a una "velocità ottimale" dipendente unicamente dalla distanza (spacing) dal veicolo precedente.¹ L'equazione differenziale che regola l'accelerazione $a(t + \Delta t)$ nell'OVM è definita come:

$$a(t + \Delta t) = k[V(h(t)) - v(t)]$$

dove k rappresenta una costante di sensibilità (che modula la rapidità della reazione del conducente), $v(t)$ è la velocità attuale e $V(h(t))$ è la funzione di velocità ottimale basata sull'headway spaziale $h(t)$.¹² Tipicamente, la funzione $V(\cdot)$ è modellata utilizzando una tangente iperbolica $\tanh(\cdot)$ per garantire transizioni asintotiche tra gli stati di veicolo fermo e veicolo a velocità di flusso libero (free-flow).¹²

L'OVM è celebre per la sua eleganza matematica e per la facilità con cui permette di condurre analisi di stabilità lineare e asintotica, fornendo equazioni chiare per determinare l'innescio di oscillazioni stop-and-go.²⁰ Tuttavia, l'OVM ha mostrato gravi carenze sotto stress: a velocità elevate o quando il differenziale di velocità con il leader è ampio, il modello genera valori di accelerazione e decelerazione fisicamente impossibili da attuare, non garantendo l'arresto a distanza di sicurezza e portando le simulazioni a registrare collisioni sistematiche.²² Pertanto, l'OVM classico è considerato inadatto come controller a bordo di veicoli autonomi senza profonde modificazioni strutturali (come il modello Full Velocity Difference - FVDM).⁷

3.3 L'Intelligent Driver Model (IDM): Lo Standard Aureo Deterministico

Per risolvere le incongruenze dell'OVM e del modello di Gipps, Treiber et al. hanno formulato nel 2000 l'Intelligent Driver Model (IDM), ampiamente considerato lo standard di riferimento per la modellazione microscopica deterministica e per la sintesi delle logiche ACC.¹ L'IDM formula un'equazione di accelerazione continua che integra il desiderio di raggiungere una velocità di crociera e la necessità di mantenere un gap dinamico:

$$a = a_{\max} \left[\frac{v_{\max} - v}{v_{\max}} \right] \left[\frac{v_{\max} - v}{v_{\max}} \right]$$

$$s^*(v, \Delta v) = s_0 + \max \left(0, vT + \frac{v\Delta v}{2\sqrt{a_{\max}b}} \right)$$

I parametri dell'IDM hanno significati fisici inequivocabili: la velocità desiderata (v_0), la massima accelerazione (a_{max}), la decelerazione confortevole (b), il gap temporale desiderato (T) e la distanza minima di arresto (s_0).⁷

Il termine $(v/v_0)^4$ modella l'accelerazione in flusso libero, diminuendo dolcemente la spinta propulsiva all'avvicinarsi alla velocità di crociera. Il termine quadratico $(s^*/\Delta x)^2$ rappresenta invece l'istinto di frenata o "interazione", che domina quando la spaziatura reale Δx è inferiore al gap dinamico desiderato s^* .⁷ A differenza dell'OVM, l'IDM include esplicitamente la differenza di velocità Δv (effetto *kinematic* o *backward-looking* proiettato in avanti) per implementare una strategia di frenata "intelligente", capace di operare in sicurezza anche a velocità elevate e di differenziare in modo nativo la decelerazione di comfort (b) da quella di emergenza, garantendo profili dinamici privi di collisioni.¹

Modello Base	Categoria Teorica	Variabili Indipendenti Principali	Prevenzione Collisioni	Limitazioni Primarie
Newell	Cinematico	Spaziatura (d_n), Ritardo (τ_n)	Parziale (statica)	Eccessiva semplificazione, assenza di asimmetria tra accelerazione e decelerazione. ¹
Gipps	Distanza di Sicurezza	Velocità, Tempi reazione, Decelerazione	Assoluta (matematica)	Frenate eccessivamente e conservative, scarsa distinzione tra comfort ed emergenza. ¹⁸
OVM	Dinamico / Fisico	Spaziatura, Velocità del	Assente ad alte velocità	Accelerazioni irrealistiche in fase di

		soggetto		transizione e alto rischio di tamponamento. ¹
IDM	Dinamico / Fisico	Spaziatura, Velocità, Differenziale (Δv)	Eccellente (dinamica)	Parametri statici incapaci di adattarsi allo stile umano senza un'integrazione di reti neurali o logica fuzzy. ¹²

Nonostante le indubbie qualità, i modelli analitici puri presentano l'intrinseco limite della deterministica rigidità: necessitano di complessi processi di calibrazione (es. tramite Algoritmi Genetici basati sul calcolo dell'errore quadratico medio RMSE o della statistica di Theil) su dataset come NGSIM o highD, faticando a catturare la natura altamente instabile, non lineare ed eterogenea della guida umana in scenari reali e caotici.²⁴

4. Ambienti V2X e l'Evoluzione del Controllo del Traffico

La modellazione microscopica sta subendo una rivoluzione dettata dalla transizione dalle architetture basate esclusivamente sui sensori on-board (Radar, LiDAR, Telecamere) ad architetture potenziate dalle comunicazioni Vehicle-to-Everything (V2X). In un ambiente tradizionale (Line-of-Sight, LOS), la percezione del veicolo è limitata al leader immediato.¹⁰ Il V2X frantuma questo limite, creando un ecosistema telematico cooperativo (Non-Line-of-Sight, NLOS) in cui i veicoli scambiano ad alta frequenza messaggi di sicurezza di base (BSM - Basic Safety Messages) comprendenti coordinate GPS, vettori di velocità, input di accelerazione e persino le intenzioni attuative del sistema frenante (intent-sharing).¹⁰

4.1 Dal Controllo Reattivo al CACC (Cooperative Adaptive Cruise Control)

L'integrazione tra sistemi di trasporto intelligenti (ITS) e protocolli V2X segna il passaggio da una mobilità reattiva a una mobilità predittiva e cooperativa.⁵ Il risultato più emblematico in ambito car-following è il Cooperative Adaptive Cruise Control (CACC). Mentre un sistema ACC basato sull'IDM reagisce ai cambiamenti del leader con un inevitabile ritardo fisico, innescando spesso oscillazioni (string instability) e onde di congestione, il CACC utilizza i collegamenti V2V (Vehicle-to-Vehicle) per formare plotoni di veicoli (platooning) sincronizzati.²⁶

Il CACC abilita l'utilizzo di logiche di controllo a distanza ridottissima (es. Constant Time Gap

policy, dimostratasi più robusta della Constant Distance Gap policy contro la propagazione degli errori).¹⁸ La condivisione dei profili di accelerazione (aggiornati tipicamente ogni 100 ms e interpolati linearmente dai sistemi riceventi) permette di attenuare l'effetto dei disturbi in direzione a monte del flusso di traffico, assicurando la stabilità di stringa (string stability).²⁹ I vantaggi operativi derivanti da questa transizione sono immensi: le simulazioni microscopiche (condotte tramite piattaforme come SUMO e VISSIM) accoppiate a modelli di emissione (come VERSIT+ o EnViVer) dimostrano che l'implementazione del CACC e di tecniche di eco-routing basate su V2X può ridurre i consumi di carburante fino al 16.8%, diminuire le emissioni di CO2 per tassi di penetrazione del 30-40%, e abbattere i ritardi fermi (stopped delay) fino al 68.7%.⁹

4.2 La Latenza di Rete: Tecnologie, Limiti e Strategie di Mitigazione

Tutti i modelli teorici di CACC assumono implicitamente una trasmissione dati perfetta. Tuttavia, nel mondo reale, la comunicazione wireless soffre di attenuazione del segnale, ombreggiamento causato da veicoli pesanti (shadowing), *packet loss* e latenza di rete.⁹ La tolleranza alla latenza è critica: studi dimostrano che ritardi V2X superiori a 1.0 secondo o ritardi medi sostenuti oltre i 500 ms compromettono l'efficacia della compensazione, innescando ampie oscillazioni nella distanza relativa e potenziali tamponamenti.²⁰

L'industria sta affrontando la sfida della latenza implementando tecnologie avanzate come il Cellular-V2X (C-V2X), basato sugli standard 3GPP LTE/5G. A differenza del tradizionale DSRC (ITS-G5 / IEEE 802.11p), il C-V2X impiega l'interfaccia "sidelink" PC5 nella banda dei 5.9 GHz per la comunicazione diretta V2V a bassissima latenza, svincolata dalla copertura della rete cellulare, mantenendo al contempo l'interfaccia Uu per le comunicazioni di rete V2N (Vehicle-to-Network) a più ampio raggio.²⁹ Valutazioni sperimentali indicano che il C-V2X può ridurre la latenza in condizioni di forte penetrazione del 99% rispetto alle soluzioni DSRC legacy, portando a una riduzione del 38% dei conflitti nel traffico a un tasso di adozione del 60%.³² Inoltre, l'utilizzo della tecnica di allocazione delle risorse Sensing-Based Semi-Persistent Scheduling (SB-SPS) migliora notevolmente il Packet Delivery Ratio (PDR).⁹

Per salvaguardare i passeggeri dai fallimenti comunicativi (perdite temporanee del segnale), le moderne architetture prevedono controllori tolleranti ai guasti. Il framework Safety Reinforced CACC (SR-CACC) implementa una strategia di controllo a doppio ramo: in caso di latenza fatale o *packet loss*, l'algoritmo attiva una transizione lineare fluida verso un modello ACC degradato, basato unicamente su telecamere e radar, garantendo la sopravvivenza del

sistema.³⁸ Similmente, approcci avanzati come l'H-infinito (H_∞) Model Predictive Control integrano soluzioni basate su disuguaglianze matriciali lineari (LMI) per compensare proattivamente ritardi di comunicazione noti (es. fino a 1.0 s), riducendo le oscillazioni di spaziatura del 41% rispetto alle baseline puramente basate su IDM.³³

Protocollo V2X	Architettura e	Vantaggi Chiave	Sfide Architetturali
----------------	----------------	-----------------	----------------------

	Frequenza	per Modelli CACC	e di Latenza
DSRC (ITS-G5)	IEEE 802.11p (5.9 GHz) ad-hoc	Ecosistema consolidato, assenza di abbonamenti cellulari, bassissima latenza in LOS e bassi volumi. ²⁹	Rapido degrado del PDR e ombreggiamento del segnale in scenari urbani ad alta densità. ³²
C-V2X Sidelink	3GPP PC5 (LTE / 5G)	Maggiore range del DSRC, uso di SB-SPS per la pre-allocazione delle collisioni di pacchetti. ³⁴	Rischio di <i>packet loss bursts</i> (cadute a raffica) che disorientano i controllori di stringa CACC continui. ⁹
C-V2X Network	3GPP Uu (Infrastruttura Cellulare)	Percezione ultra-macroscopica (V2N/V2I), ottimizzazione semaforica ML/Edge Computing integrata. ⁵	Maggiore E2E (End-to-End) latency in assenza di nodi MEC (Multi-access Edge Computing) prossimi. ³⁹

5. Modelli Guidati dai Dati, Reinforcement Learning e Architetture Ibride

Mentre i modelli cinematici e fisici (Newell, IDM) garantiscono coerenza fisica ed equazioni maneggevoli, essi risultano intrinsecamente limitati, con un "bias elevato" che impedisce di replicare l'estrema non linearità, le asimmetrie decisionali e l'eterogeneità dei comportamenti umani.¹² L'avvento dei Big Data nel settore automobilistico (grazie ai bus CAN e alla sensoristica V2X) ha aperto la strada a modelli puramente *data-driven*, in cui le relazioni tra velocità relative e accelerazioni non sono preimpostate, ma dedotte. Tuttavia, il Machine Learning puro soffre spesso del problema opposto: un'eccessiva "varianza". Le reti neurali operano come *black-box*, manifestando comportamenti instabili o catastrofici (alte probabilità di collisione nei simulatori) se poste di fronte a input *out-of-distribution* non contemplati nel dataset di addestramento.¹² La frontiera tecnologica risiede pertanto in paradigmi avanzati e architetture ibride.

5.1 Deep Reinforcement Learning (DRL) e Controllo Predittivo

Il Deep Reinforcement Learning (DRL) è emerso come una metodologia dominante per ottimizzare le politiche di controllo CACC senza necessitare di complesse equazioni differenziali esatte per l'ambiente stocastico. In un framework DRL (come DDPG o TD3), un agente apprende per tentativi ed errori massimizzando una "funzione di ricompensa" (reward function) personalizzata, che può ponderare selettivamente parametri quali la minimizzazione della deviazione di velocità, il contenimento del *jerk* (derivata dell'accelerazione, fondamentale per il comfort) e l'efficienza dei consumi.¹⁸

Rispetto al Model Predictive Control (MPC) puro, che richiede pesanti ottimizzazioni numeriche in tempo reale su lunghi orizzonti di predizione, i controller DRL addestrati offline spostano la complessità computazionale nella fase di training, offrendo latenze di inferenza online molto più basse. Studi dimostrano che algoritmi come l'Actor-Critic o il Twin Delayed Deep Deterministic Policy Gradients (TD3), integrati con reti Seq2Seq (Sequence-to-Sequence) per prevedere le incertezze di movimento dei veicoli circostanti, superano sia gli algoritmi MPC convenzionali sia i conducenti umani in termini di rapidità di smorzamento delle onde di traffico e gestione dell'efficienza stradale.¹⁸

5.2 L'Avvento delle Physics-Informed Neural Networks (PINNs)

Per risolvere il conflitto tra la rigidità dei modelli fisici e la scatola nera del Deep Learning, l'industria ha introdotto il paradigma del Physics-Informed Deep Learning per il Car-Following (PIDL-CF), basato sulle Physics-Informed Neural Networks (PINN). Le architetture PINN fondono i due mondi codificando esplicitamente le equazioni deterministiche (es. le leggi dell'IDM o dell'OVM) all'interno della rete neurale stessa.¹²

A livello strutturale, un modello PIDL-CF si articola tipicamente in due grafi computazionali paralleli. Il primo è una rete neurale (Spesso una LSTM, Long Short-Term Memory, o una Rete Neurale Artificiale pura, PUNN) che apprende le dinamiche asimmetriche direttamente dai dati di traiettoria. Il secondo è un grafo computazionale basato sulla fisica, le cui operazioni matematiche replicano fedelmente le equazioni differenziali ordinarie dell'IDM o dell'OVM. Durante la fase di addestramento (backpropagation), la funzione di perdita (Loss function) viene arricchita con un termine di regolarizzazione che misura la discrepanza o "penalità" tra l'accelerazione prevista dalla rete neurale e l'accelerazione fisicamente coerente calcolata dal modello cinematico.⁷

I vantaggi delle reti PINN per il car-following sono monumentali:

1. **Data Efficiency:** Essendo ancorate a regole fisiche, le PINN non richiedono i vasti volumi di dati dei modelli puramente neurali. Test condotti sul dataset NGSIM dimostrano che un modello PIDL-IDM supera costantemente i modelli basati su reti neurali tradizionali anche in condizioni di estrema sparsità dei dati, ad esempio con soli 25 punti campione.¹²
2. **Identificazione dei Parametri:** I modelli PIDL-CF consentono non solo di prevedere con estrema accuratezza i valori longitudinali nelle quattro fasi di traffico (crociera,

accelerazione, decelerazione, frenata di emergenza), ma di *scoprire* e ottimizzare dinamicamente i parametri fisici nascosti (come la sensibilità del conducente o la distanza desiderata), fungendo da eccezionali strumenti di calibrazione e astrazione dello stile di guida.¹²

3. **Sicurezza Predittiva in Reti Ibride:** Utilizzando varianti auto-supervisionate come il Recurrent Predictive Control (RPC), che sfrutta reti neurali differenziabili combinate con vincoli cinematici del veicolo reale, è possibile raggiungere percentuali di successo del 100% nei cambi di corsia, riducendo i tempi di risoluzione computazionale di oltre il 95.9% rispetto all'MPC tradizionale.⁴⁵

Ulteriori raffinamenti sono offerti dalle reti generative, come le Generative Adversarial Networks informate dalla fisica (PICGAN). A differenza delle PINN tradizionali che richiedono un delicato bilanciamento manuale dei pesi (weighting parameters) tra la componente dati e quella fisica, il modello PICGAN utilizza un discriminatore per valutare autonomamente l'aderenza delle traiettorie sintetiche generate alle dinamiche fisiche di laboratorio (come i modelli implementati nel PATH laboratory).⁷ Tali modelli offrono una riproduzione delle traiettorie multi-step eccezionalmente robusta, fondamentale per le simulazioni CAV in flussi di traffico misto.⁷

6. Il Collo di Bottiglia Computazionale: La Necessità dell'Accelerazione Hardware

Tutti i paradigmi di elaborazione V2X e le complesse reti PINN o DRL finora discussi convergono verso un imponente collo di bottiglia: l'infrastruttura computazionale a bordo del veicolo (Edge Computing). Sebbene teoricamente promettenti, le reti neurali richiedono un'immensa capacità matematica. È stimato che un veicolo autonomo in movimento debba elaborare circa 2 GB di dati grezzi al secondo provenienti da decine di telecamere, moduli LiDAR, radar e antenne V2X.⁴⁷

In scenari ad alta densità urbana e traffico misto, il ciclo decisionale del modello di car-following — che comprende la ricezione dei pacchetti C-V2X, l'estrazione delle feature visive, l'inferenza del modello PIDL/DRL e il calcolo del vettore attuativo — deve essere completato con tolleranze di latenza estreme per mantenere lo standard dell'industria di 30 Frame Per Secondo (FPS).

Ciò lascia una finestra di esecuzione operativa di soli ≈ 33 millisecondi per frame. Se l'inferenza impiega un tempo maggiore, l'intera pipeline si blocca, causando omissione di fotogrammi (frame drops) e portando il veicolo a operare in uno stato di "cecità temporanea" ad alta velocità, con esiti catastrofici per la stabilità di stringa del CACC.¹³

Per risolvere questa problematica, il settore automotive ha dovuto abbandonare le architetture tradizionali basate unicamente sulle unità di elaborazione centrale (CPU), abbracciando soluzioni eterogenee su chip (SoC) dotate di acceleratori hardware specifici per l'Intelligenza Artificiale (AI Accelerators).

6.1 L'Inadeguatezza della Central Processing Unit (CPU)

Le CPU tradizionali sono processori "general-purpose", progettati per elaborare istruzioni in sequenza. Sono ottimizzate per eseguire logiche decisionali condizionali e gestire database strutturati o task di rete, offrendo latenze bassissime su singoli thread, ma falliscono drammaticamente di fronte a compiti computazionali massicci e non strutturati.⁴⁸

Il calcolo delle reti neurali (sia durante l'addestramento che nell'inferenza) è dominato dalle operazioni di algebra lineare (moltiplicazioni e addizioni di matrici o dot-product). Una CPU, pur dotata di core molto potenti e cache L1/L2 ad alta frequenza, esegue queste istruzioni in modo largamente seriale. Di conseguenza, nel benchmarking di modelli standard di visione artificiale e percezione del traffico in alta precisione (FP32), una CPU tradizionale raggiunge throughput critici (spesso inferiori a 1.0 FPS) e latenze inaccettabili, superando ampiamente i 1000 ms per frame.¹³ Inoltre, per via della limitata efficienza architetturale in questo dominio, il dispendio energetico risulta penalizzante (stimato in circa 3.5 - 6.0 mJ per singola inferenza di modelli leggeri come MobileBERT).⁵¹

6.2 L'Ascesa delle Graphics Processing Unit (GPU)

Le Graphics Processing Unit (GPU), originariamente progettate per il rendering parallelo di pixel grafici, possiedono una topologia diametralmente opposta. Esse ospitano migliaia di core di calcolo aritmetico-logico (ALU) semplificati che lavorano all'unisono secondo il paradigma SIMD (Single Instruction, Multiple Data).⁴⁸ Guidate dall'API CUDA (Compute Unified Device Architecture) o ROCm, le GPU rappresentano la forza trainante dietro i Large Language Models (LLMs) e il training offline dei modelli DRL per il car-following.⁴⁸

Nell'architettura automobilistica, le GPU edge di altissimo livello dominano gli stack di percezione avanzati. Sistemi SoC come la serie NVIDIA DRIVE Orin racchiudono miliardi di transistor, integrando decine di core ARM assieme ad architetture GPU di classe Ampere, capaci di erogare prestazioni fino a 254 TOPS (Triloni di Operazioni al Secondo) per singolo chip e scalare fino a oltre 1000 TOPS in configurazioni quad-chip, gestendo agevolmente i carichi di reti di rilevazione multiple, algoritmi LiDAR e moduli di pianificazione.⁵⁴ Le metriche indicano che le GPU superano altre piattaforme nelle moltiplicazioni matrice-matrice dense e nelle reti LSTM pesanti (con throughput fino a 2.7 volte superiori).⁵⁶

Tuttavia, l'implementazione delle GPU nel dominio automobilistico V2X incontra un duplice ostacolo: il collo di bottiglia della cache e l'assorbimento termico/energetico. Nonostante l'elevata potenza di calcolo parallela, il calcolo tensoriale massivo su GPU richiede di spostare ininterrottamente enormi quantità di dati dalla VRAM esterna alle memorie interne, generando consumi che vanno dai 10W fino a 60W per singolo nodo Edge, richiedendo complessi sistemi di raffreddamento attivo.⁴⁹ Un recente studio del MIT ha calcolato che, se il parco globale di veicoli autonomi (ipotizzato a 1 miliardo di unità) dovesse affidarsi ad hardware con consumi attorno agli 840W per vettura, la richiesta energetica produrrebbe emissioni di gas serra equivalenti o superiori a quelle generate oggi da tutti i data center globali.⁵⁹

7. Le Neural Processing Units (NPU) e le Tensor Processing Units (TPU)

Per conciliare l'esigenza di un controllo in tempo reale sub-millisecondo con limiti di consumo energetico perentori (sotto i 10 Watt), i produttori di silicio hanno sviluppato acceleratori dedicati esclusivamente all'esecuzione di reti neurali, comunemente noti come Neural Processing Units (NPU), AI Accelerators, o Tensor Processing Units (TPU per le varianti proprietarie di Google).⁴⁸ L'architettura SoC moderna, come la serie NXP S32 Automotive o il Qualcomm Snapdragon Ride (con potenze NPU integrate fino a 45 TOPS per modulo), basa le sue capacità inferenziali interamente su questa tecnologia.⁶¹

7.1 Architettura Dataflow e Unità MAC

Il principio ingegneristico che distingue una NPU da una GPU è il superamento del tradizionale paradigma di Von Neumann a favore di un'architettura spaziale orientata al flusso dei dati (Dataflow Architecture). Piuttosto che impiegare core ALU convenzionali, una NPU è composta da giganteschi array (reti sistoliche) di unità MAC (Multiply-Accumulate), hardware esplicitamente scolpito nel silicio per risolvere l'operazione matematica di base delle reti neurali: moltiplicare un peso per un input e sommare il risultato in un accumulatore continuo in un singolo ciclo di clock.⁶⁰

In questo modo, la NPU minimizza la necessità di leggere e scrivere ripetutamente risultati intermedi nella memoria principale, passandoli direttamente da un'unità MAC adiacente all'altra. Le specifiche prestazionali grezze vengono solitamente misurate in TOPS (Trillion Operations Per Second), calcolate secondo la formula:

$$TOPS = 2 \times \text{Numero di unità MAC} \times \text{Frequenza (Hz)} / 10^{12} \quad .62$$

I benchmark sperimentali rivelano il trionfo assoluto di questa architettura nel calcolo V2X *edge*:

- **Prestazioni di Latenza:** Per le operazioni computazionali più comuni nell'inferenza dei modelli di car-following (come le moltiplicazioni matrice-vettore utilizzate per trasformare i tensori di input spaziali V2X), le NPU riducono la latenza di ben il 58.54% rispetto a una GPU di fascia equivalente.⁵⁶ Per l'inferenza di reti LLM leggere o modelli di predizione comportamentale, le NPU hanno dimostrato velocità fino a 3.2 volte superiori rispetto alle GPU, mantenendo prestazioni coerenti indipendentemente dalle dimensioni del *batch* (a differenza della GPU, che eccelle solo quando elabora enormi lotti simultanei, operazione rara in un'auto che necessita decisioni immediate su frame sequenziali).⁵⁶
- **Efficienza Energetica:** La NPU esegue le inferenze neurali a frequenze di clock moderate, annullando il degrado della batteria o le limitazioni termiche dei sistemi *fanless*. Il costo energetico dell'inferenza in una NPU mobile o dedicata oscilla tipicamente tra i 0.7 e i 1.2 millijoule per inferenza (mJ/inf), offrendo riduzioni di consumo del 35-70% rispetto a una GPU equivalente (2.5-4.0 mJ/inf) e garantendo operatività fluida a 30 FPS con consumi complessivi tra 2.5W e 7.5W.¹³

Un'estremizzazione di questo concetto per i sensori V2X periferici (fotocamere per infrastrutture stradali V2I) è l'Edge TPU di Google (es. dispositivi Coral). Questi microchip ASIC (Application-Specific Integrated Circuit) forniscono un impressionante rapporto potenza/watt di 2 TOPS per Watt (es. 4 TOPS assorbendo soli 2W), eccellendo in contesti IoT dove il budget termico è quasi nullo.⁵⁷ Tuttavia, gli ASIC come le Edge TPU presentano limitazioni in termini di flessibilità: possono eseguire esclusivamente logiche congelate nei linguaggi per i quali sono progettati (come TensorFlow Lite) e non permettono l'esecuzione di reti neurali custom o architetture sperimentali complesse senza severi compromessi architetturali.⁶⁶

Acceleratore Edge	Categoria Architettuale	Potenza di Calcolo Dichiarata	Consumo Stimato (TDP/Watt)	Caso d'Uso Dominante nel Trasporto Autonomo
NVIDIA Orin / AGX	GPU (Ampere/Tensor Cores)	254 - 275 TOPS (per singolo SoC)	10W - 60W	Elaborazione centrale pesantemente multi-thread, fusione sensoriale complessa 3D, Radar/LiDAR processing ad alte prestazioni. ⁵⁴
EdgeCortex SAKURA	NPU (architettura dinamica)	~ 60 TOPS	< 10W	Reti DRL e CACC embedded ad altissima efficienza con supporto generativo (GenAI) limitato. ⁵⁷
Hailo-8 / Ambarella	NPU / DSP specifici (Vision)	20 - 26 TOPS	2.5W - 5W	Riconoscimento video multicamera (YOLO) in

				tempo reale, tracking oggetti e sistemi ADAS ausiliari. ¹⁴
Google Edge TPU	ASIC (TensorFlow Lite)	4 TOPS	~ 2W	Sensori urbani, telecamere V2I a batteria o sistemi con requisiti di calore e peso critici (droni/wearable). ⁵⁷

8. Ottimizzazione del Deployment e Co-Design Hardware/Software

L'integrazione di reti neurali informate dalla fisica (PINN) in unità NPU non è un'operazione "plug-and-play". Se la struttura hardware è il motore, i compilatori e il design dei modelli sono la trasmissione. Le discrepanze tra la programmazione teorica in Python (FP32) e i rigidi registri hardware delle NPU richiedono profonde ottimizzazioni dell'infrastruttura software per il raggiungimento delle latenze V2X (Sub-33ms).

8.1 Quantizzazione e Pruning dei Modelli

La Quantizzazione è la tecnica di compressione algoritmica cardine per gli Edge Accelerators. I pesi matematici generati dall'addestramento su server cloud (con virgola mobile a 32 bit, FP32) vengono arrotondati e convertiti in rappresentazioni intere a precisione inferiore (solitamente INT8 o perfino sub-4-bit per le NPU altamente specializzate).⁶² Il passaggio da FP32 a INT8 riduce drasticamente i requisiti di larghezza di banda della memoria e lo spazio di archiviazione della SRAM, comprimendo le dimensioni del modello in un rapporto di 4:1. Sebbene la quantizzazione pura possa influire sull'accuratezza (specialmente in compiti di percezione di piccoli ostacoli stradali a distanza), tecniche avanzate di *Quantization-Aware Training* (QAT) e precisione mista (mantenendo FP16 nei livelli iniziali e terminali della rete) minimizzano il degrado della precisione mAP (mean Average Precision) a meno dell'1-3%, garantendo aumenti di velocità da 2.5 a 3.2 volte.⁶⁷

Parallelamente, la potatura strutturale (*Pruning*) interviene sull'inefficienza delle reti neurali fortemente sovra-parametrizzate. Studi applicati ai modelli di percezione autonoma dimostrano che il 30-70% dei parametri in architetture come le CNN contribuisce minimamente all'accuratezza dell'output. Eliminando interi filtri o blocchi di pesi irrilevanti e riaddestrando la

rete, le operazioni matematiche (FLOPs) vengono ridotte di oltre 3 volte senza alterare le dinamiche del controllo vettoriale.⁶⁸

8.2 Compilatori Edge e Gestione del Flusso Dati AHardwareBuffer

L'ecosistema dei compilatori funge da ponte tra le logiche di programmazione astratte e le strutture fisiche in silicio. Il deployment dei modelli di car-following PINN e CACC sulle unità NPU mobili è governato da interfacce come LiteRT (precedentemente TensorFlow Lite per NPU MediaTek e Qualcomm) o TensorRT (per ecosistemi NVIDIA).⁷⁰ Questi framework supportano sia la compilazione AOT (Ahead-of-Time, che trasforma il modello in binari macchina precompilati ideali per SoC noti a bordo del veicolo per abbattere il costo di inizializzazione della memoria), sia la compilazione JIT (Just-In-Time).⁷⁰

Il più critico intervento di ottimizzazione risiede tuttavia nella manipolazione della memoria. Le operazioni di passaggio dati tra i core della CPU, la memoria di sistema (DRAM) e l'acceleratore AI comportano colli di bottiglia e latenze ingestibili. Interfacce C++ native, come quelle di LiteRT integrate con AHardwareBuffer in ambienti SoC eterogenei, eliminano questo problema ricorrendo alla cosiddetta interoperabilità dei buffer hardware *Zero-Copy*. Piuttosto che tradurre e copiare i frame della videocamera o i vettori di telemetria V2X avanti e indietro tra i bus della CPU e la NPU, l'infrastruttura assegna un indirizzo di memoria univoco in Direct Memory Access (DMA), consentendo al sensore, alla GPU (per l'eventuale filtraggio OpenGL delle immagini) e alla NPU di accedere sequenzialmente e in tempo reale ai medesimi registri di memoria, sbloccando throughput estremi.⁵⁶ Ulteriori strumenti, come gli scheduler hardware per la virtualizzazione NPU, sono impiegati per pre-caricare i dati nella SRAM (pre-fetching), risolvendo le contese di memoria in scenari multithreading in cui il veicolo deve calcolare contemporaneamente la dinamica longitudinale del CACC e rilevare pedoni nel traffico urbano.⁷²

9. Analisi del Ciclo di Vita Energetico e Sostenibilità Computazionale

Un elemento chiave, spesso trascurato nella pura equazione della latenza, è l'impronta di carbonio e il consumo energetico a lungo termine delle reti V2X automatizzate. Un'integrazione di AI hardware in un'architettura automobilistica non deve solo risolvere i tempi di reazione sub-millisecondo, ma deve affrontare la sostenibilità ambientale su larga scala.

Le architetture eterogenee GPU e NPU stanno abbattendo le barriere di efficienza energetica con ratei impressionanti, consentendo di ottenere risparmi che superano le mere valutazioni sul powertrain meccanico. Mentre il calcolo del training nei data center cloud consuma energia elettrica massiva (centinaia di Watt per GPU), si stima che oltre il 90% dell'energia consumata dall'Intelligenza Artificiale durante la vita utile di un modello derivi dall'inferenza quotidiana nei dispositivi periferici (Edge AI).⁷⁴

Per mantenere l'incremento potenziale delle flotte di CAV (con previsioni di decine di milioni di

veicoli costantemente interconnessi a server 5G/6G) senza causare collassi delle reti elettriche globali, la ricerca di architetture co-ottimizzate risulta imperativa. I modelli di benchmarking MLPerf dimostrano che le NPU riducono le emissioni operative derivanti dal calcolo inferenziale di oltre 58 volte rispetto alle architetture ottimizzate esclusivamente per le pure prestazioni, confermando l'accelerazione hardware AI specializzata come l'unico veicolo tecnologico capace di tradurre le complesse equazioni di ottimizzazione del traffico cooperativo in una realtà applicabile, pulita e scalabile.⁷⁵

10. Conclusioni

La teoria del car-following si è evoluta dalle astrazioni deterministiche e lineari del modello di Newell e dalla rigidità di sistemi come l'Optimal Velocity Model (OVM) a configurazioni dinamiche sofisticate come l'Intelligent Driver Model (IDM). Sebbene questi ultimi garantiscano robustezza per prevenire le collisioni attraverso un rigoroso controllo matematico delle fasi di frenata, le loro euristiche predefinite mostrano lacune di fronte all'incertezza, alla stocasticità dei comportamenti umani e alla dinamica multidimensionale propria del Cooperative Adaptive Cruise Control (CACC).

Il paradigma delle Physics-Informed Neural Networks (PINNs) si è saldamente imposto come l'architettura risolutiva in tale ambito. Abbinando il pragmatismo matematico delle equazioni IDM come termine di regolarizzazione alla flessibilità percettiva delle reti neurali e di costrutti DRL generativi (come il PICGAN), è possibile progettare controller veicolari predittivi e ad altissima efficienza di campionamento. Questi framework garantiscono stabilità di stringa (string stability) superando di gran lunga le tradizionali limitazioni di "high bias" (rigidità fisica) o "high variance" (imprevedibilità del machine learning puro).

Tuttavia, l'implementazione del CACC e delle reti neurali impone barriere computazionali e di latenza severissime in ambienti V2X, dove la tolleranza al ritardo per garantire la sicurezza oscilla spesso al di sotto dei 100 ms. A bordo veicolo, l'architettura Central Processing Unit (CPU) cede inesorabilmente il passo per incapacità operativa nell'algebra matriciale densa, mentre le GPU — straordinarie per flessibilità e parallelismo massivo (ideali per LLM e sensori 3D HD) — presentano assorbimenti termici ed energetici ostili alle sfide dell'ottimizzazione a bordo (superiori ai 60W). Il cuore pulsante dell'innovazione ingegneristica risiede nelle Neural Processing Units (NPU) e nei chip ASIC *dataflow* (come l'Edge TPU). Attraverso macro array di unità MAC per il calcolo tensoriale diretto in memoria zero-copy e tecniche di compressione in formato INT8 (quantizzazione), le NPU permettono inferenze sub-millisecondo a 30 FPS con consumi nominali limitati a 2.5 - 7 Watt.

La piena transizione verso una gestione automatizzata e connessa delle nostre infrastrutture urbane non è quindi una mera questione algoritmica: essa rappresenta il trionfo e la maturità del paradigma del *co-design* Hardware-Software, dove le equazioni fisiche della fluidodinamica del traffico trovano la loro definitiva esecuzione in strutture di silicio a basso consumo orientate all'Intelligenza Artificiale.

Bibliografia

1. Car-Following Models for Human-Driven Vehicles and Autonomous Vehicles: A Systematic Review | Journal of Transportation Engineering, Part A - ASCE Library, accesso eseguito il giorno aprile 7, 2026, <https://ascelibrary.org/doi/10.1061/JTEPBS.TEENG-7836>
2. Microscopic Traffic Flow Models: a survey for mixed autonomous vehicles flow, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/394951390_Microscopic_Traffic_Flow_Models_a_survey_for_mixed_autonomous_vehicles_flow
3. An extended car-following model considering backward-looking effect: A machine learning approach - Canadian Science Publishing, accesso eseguito il giorno aprile 7, 2026, <https://cdnsiencepub.com/doi/10.1139/cjce-2023-0018>
4. Automatic Calibration of Microscopic Traffic Simulation Models Using Artificial Neural Networks - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/23/21/8798>
5. Advancements in accident-aware traffic management: a comprehensive review of V2X-based route optimization - PMC, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12508076/>
6. Car-Following Models: A Multidisciplinary Review - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2304.07143v5>
7. A Physics-Informed Generative Car-Following Model for Connected Autonomous Vehicles, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1099-4300/25/7/1050>
8. Autonomous Vehicles: Evolution of Artificial Intelligence and the Current Industry Landscape, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2504-2289/8/4/42>
9. Quantifying the Impact of Cellular Vehicle-to- everything (C-V2X) on Transportation System Efficiency, Energy and Environment - Morgan State University, accesso eseguito il giorno aprile 7, 2026, <https://www.morgan.edu/Documents/ACADEMIA/CENTERS/ntc/umec/UMEC-Final%20report%20051%20-%20C-V2X%20Research.pdf>
10. Evaluating V2X-Based Vehicle Control under Unreliable Network Conditions, Focusing on Safety Risk - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2076-3417/14/13/5661>
11. Comparing driving behavior of humans and autonomous driving in a professional racing simulator - PMC, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7857611/>
12. A Physics-Informed Deep Learning Paradigm for Car-Following Models - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/pdf/2012.13376>
13. NPU vs. CPU: Edge AI Benchmarks for Real-Time Vision - Silex Technology, accesso eseguito il giorno aprile 7, 2026, <https://www.silextechnology.com/unwired/npu-vs-cpu-object-detection-benchmarks>
14. The acceleration of artificial intelligence in automotive. - Ambarella, accesso eseguito il giorno aprile 7, 2026,

- <https://www.ambarella.com/blog/the-acceleration-of-ai-in-automotive/>
15. A car-following model with the consideration of vehicle-to-vehicle communication technology - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/298815615_A_car-following_model_with_the_consideration_of_vehicle-to-vehicle_communication_technology
 16. Energy Efficiency of Connected Autonomous Vehicles: A Review - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/12/19/4086>
 17. file_177-summits-24-4-uluslararası-akilli-ulasim-sistemleri-zirvesi-bildiriler-kitabi-70.pdf - AUS TÜRKİYE, accesso eseguito il giorno aprile 7, 2026, https://austurkiye.org.tr/uploads/dosyalar/file_177-summits-24-4-uluslararası-akilli-ulasim-sistemleri-zirvesi-bildiriler-kitabi-70.pdf
 18. Car-Following Models: A Multidisciplinary Review - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2304.07143v4>
 19. Improving car-following model to capture unobserved driver heterogeneity and following distance features in fog condition | Request PDF - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/359380589_Improving_car-following_model_to_capture_unobserved_driver_heterogeneity_and_following_distance_features_in_fog_condition
 20. An enhanced optimal velocity model for car-following with connected and autonomous vehicles - OAE Publishing Inc., accesso eseguito il giorno aprile 7, 2026, <https://www.oaepublish.com/articles/ces.2025.60>
 21. Microscopic car-following model for the traffic flow: The state of the art - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/257733050_Microscopic_car-following_model_for_the_traffic_flow_The_state_of_the_art
 22. The Car-Following Model and Its Applications in the V2X Environment: A Historical Review, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1999-5903/14/1/14>
 23. Comparison of Vehicle Dynamics of Microscopic Car Following Models: Optimal Velocity and Intelligent Driver Model - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/323400960_Comparison_of_Vehicle_Dynamics_of_Microscopic_Car_Following_Models_Optimal_Velocity_and_Intelligent_Driver_Model
 24. ESTIMATION OF CAR-FOLLOWING MODEL PARAMETERS DISTRIBUTION USING BOOTSTRAP METHOD - Transportation Research Board (TRB), accesso eseguito il giorno aprile 7, 2026, <https://onlinepubs.trb.org/onlinepubs/conferences/2011/RSS/3/Wu.F.pdf>
 25. Development of Data-driven Car-following Models - mediaTUM, accesso eseguito il giorno aprile 7, 2026, <https://mediatum.ub.tum.de/doc/1596704/pq8idxvb7g2vwi9e13p1yd3ge.pdf>
 26. A data-driven behavior generation algorithm in car-following scenarios - Carnegie Mellon University Robotics Institute, accesso eseguito il giorno aprile 7, 2026, https://www.ri.cmu.edu/app/uploads/2019/04/IAVSD_248.pdf

27. A Hardware-in-the-Loop V2X Simulation Framework: CarTest - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/22/13/5019>
28. Real-Time Distributed Cooperative Adaptive Cruise Control Model Considering Time Delays and Actuator Lag | Request PDF - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/360694382_Real-Time_Distributed_Cooperative_Adaptive_Cruise_Control_Model_Considering_Time_Delays_and_Actuator_Lag
29. (PDF) Practical Challenges in CACC Communication: ITS G5, LTE Uu, and LTE Sidelink PC5 - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/357549137_Practical_Challenges_in_CACC_Communication_ITS_G5_LTE_Uu_and_LTE_Sidelink_PC5
30. Decentralized Control Framework for Optimal Platoon Spacing and Energy Efficiency - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/14/1/169>
31. Adapting Time Headway in Cooperative Adaptive Cruise Control to Network Reliability - Clemson University, accesso eseguito il giorno aprile 7, 2026, https://people.computing.clemson.edu/~jmarty/papers/ieee_tvt_final_version.pdf
32. Cooperative Intelligent Transport Systems: The Impact of C-V2X Communication Technologies on Road Safety and Traffic Efficiency - PMC, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11990983/>
33. Robust H^∞ MPC method for heterogeneous CACC system with communication delay, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/391387682_Robust_H_MPC_method_for_heterogeneous_CACC_system_with_communication_delay
34. Experimental V2X Evaluation for C-V2X and ITS-G5 Technologies in a Real-Life Highway Environment | Request PDF - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/356398166_Experimental_V2X_Evaluation_for_C-V2X_and_ITS-G5_Technologies_in_a_Real-Life_Highway_Environment
35. Vehicle-to-Everything Cooperative Perception for Autonomous Driving - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2310.03525v5>
36. A Feasibility Study of LTE-V2X Semi-Persistent Scheduling for String Stable CACC - Vodafone Chair, accesso eseguito il giorno aprile 7, 2026, https://www.vodafone-chair.org/pbls/arturo-gonzalez-rodriguez/A_Feasibility_Study_of_LTE-V2X_Semi-Persistent_Scheduling_for_String_Stable_CACC.pdf
37. PR-CARA: Proactive V2X Resource Allocation with Extended 1-Stage SCI and Deep Learning-based Sensing Matrix Estimator - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2412.13767v1>
38. A Safety Reinforced Cooperative Adaptive Cruise Control Strategy Accounting for Dynamic Vehicle-to-Vehicle Communication Failure - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/21/18/6158>
39. How Does C-V2X Help Autonomous Driving to Avoid Accidents? - PMC - NIH, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC8779724/>

40. Formulation and validation of a car-following model based on deep reinforcement learning, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/abs/2109.14268>
41. A Deep Reinforcement Learning Approach for Efficient, Safe and Comfortable Driving, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2076-3417/13/9/5272>
42. Deep Reinforcement Learning Car-Following Control Based on Multivehicle Motion Prediction - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/13/6/1133>
43. Fast and Accurate Prediction of Vehicle Dynamics using Physics-Informed Neural Networks - TechRxiv, accesso eseguito il giorno aprile 7, 2026, <https://www.techrxiv.org/users/867892/articles/1250938/master/file/data/vehicle-pinns/vehicle-pinns.pdf>
44. A physics-informed deep learning paradigm for car-following models - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/353120353_A_physics-informed_deep_learning_paradigm_for_car-following_models
45. Physics-informed Machine Learning with Heuristic Feedback Control Layer for Autonomous Vehicle Control - Mitsubishi Electric Research Laboratories, accesso eseguito il giorno aprile 7, 2026, <https://www.merl.com/publications/docs/TR2025-087.pdf>
46. Physics-informed Machine Learning for Autonomous Vehicle Control - ROSA P, accesso eseguito il giorno aprile 7, 2026, https://rosap.ntl.bts.gov/view/dot/86347/dot_86347_DS1.pdf
47. Autonomous Vehicles Enabled by the Integration of IoT, Edge Intelligence, 5G, and Blockchain - PMC, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9963447/>
48. What's the Difference Between AI accelerators and GPUs? - IBM, accesso eseguito il giorno aprile 7, 2026, <https://www.ibm.com/think/topics/ai-accelerator-vs-gpu>
49. What to Know About AI Hardware Accelerators: NPUs, TPUs, and Beyond - HP, accesso eseguito il giorno aprile 7, 2026, <https://www.hp.com/us-en/shop/tech-takes/ai-hardware-accelerators-npu-tpu-gpu-guide>
50. Choosing the Right AI Accelerator | NPU or TPU for Edge and Cloud Applications, accesso eseguito il giorno aprile 7, 2026, <https://www.gateworks.com/choosing-the-right-ai-accelerator-npu-or-tpu-for-edge-and-cloud-applications/>
51. Lightweight Transformer Architectures for Edge Devices in Real-Time Applications - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2601.03290v1>
52. CPU, GPU, and NPU: Understanding Key Differences and Their Roles in Artificial Intelligence | by Antonio Troise, accesso eseguito il giorno aprile 7, 2026, <https://levysoft.medium.com/cpu-gpu-and-npu-understanding-key-differences-and-their-roles-in-artificial-intelligence-2913a24d0747>

53. FPGA vs GPU vs CPU vs MCU – hardware options for AI applications | Avnet Silica, accesso eseguito il giorno aprile 7, 2026,
<https://my.avnet.com/silica/resources/article/fpga-vs-gpu-vs-cpu-hardware-options-for-ai-applications/>
54. The New Era of Transportation Is Built on NVIDIA DRIVE Orin, accesso eseguito il giorno aprile 7, 2026,
<https://blogs.nvidia.com/blog/new-era-transportation-drive-orin/>
55. NVIDIA Orin SoC Analysis for ADAS - aivon, accesso eseguito il giorno aprile 7, 2026,
<https://www.aivon.com/blog/automotive-electronics/nvidia-orin-soc-analysis-for-ad-as/>
56. Benchmarking Edge AI Platforms for High-Performance ML Inference - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2409.14803v1>
57. Top 15 Edge AI Chip Makers with Use Cases in 2026 - AIMultiple, accesso eseguito il giorno aprile 7, 2026, <https://aimultiple.com/edge-ai-chips>
58. CPU vs GPU vs TPU vs NPU: AI Hardware Architecture Guide 2025 - The Purple Struct, accesso eseguito il giorno aprile 7, 2026,
<https://www.thepurplestruct.com/blog/cpu-vs-gpu-vs-tpu-vs-npu-ai-hardware-architecture-guide-2025>
59. Computers that power self-driving cars could be a huge driver of global carbon emissions, accesso eseguito il giorno aprile 7, 2026,
<https://news.mit.edu/2023/autonomous-vehicles-carbon-emissions-0113>
60. NPU vs GPU: What's the Difference? - IBM, accesso eseguito il giorno aprile 7, 2026, <https://www.ibm.com/think/topics/npu-vs-gpu>
61. Automotive Edge AI | NXP Semiconductors, accesso eseguito il giorno aprile 7, 2026,
<https://www.nxp.com/applications/technologies/ai-and-machine-learning/automotive-edge-ai:AUTOMOTIVE-EDGE-AI>
62. A guide to AI TOPS and NPU performance metrics | Qualcomm, accesso eseguito il giorno aprile 7, 2026,
<https://www.qualcomm.com/news/onq/2024/04/a-guide-to-ai-tops-and-npu-performance-metrics>
63. Steering Towards Heterogeneous Compute for ADAS | Qualcomm, accesso eseguito il giorno aprile 7, 2026,
<https://www.qualcomm.com/content/dam/qcomm-martech/dm-assets/documents/Efficient-Heterogeneous-Compute-Architecture-for-ADAS-ECUs.pdf>
64. Performance and Efficiency Gains of NPU-Based Servers over GPUs for AI Model Inference, accesso eseguito il giorno aprile 7, 2026,
<https://www.mdpi.com/2079-8954/13/9/797>
65. Edge TPU performance benchmarks - Coral, accesso eseguito il giorno aprile 7, 2026, <https://www.coral.ai/docs/edgetpu/benchmarks/>
66. Edge Machine Learning: From PoC to Real-World AI Applications - Medium, accesso eseguito il giorno aprile 7, 2026,
<https://medium.com/@stronganalytics/edge-machine-learning-from-poc-to-real-world-ai-applications-ec96940487f3>

67. Edge AI in Practice: A Survey and Deployment Framework for Neural Networks on Embedded Systems - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/14/24/4877>
68. Real-Time AI Inference at the Edge for Self- Driving Cars - IJSAT, accesso eseguito il giorno aprile 7, 2026, <https://www.ijsat.org/papers/2025/1/2462.pdf>
69. Optimizing Real-Time Object Detection in a Multi-Neural Processing Unit System - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/25/5/1376>
70. NPU acceleration with LiteRT | Google AI Edge, accesso eseguito il giorno aprile 7, 2026, <https://ai.google.dev/edge/litert/next/npu>
71. MediaTek NPU and LiteRT: Powering the next generation of on-device AI, accesso eseguito il giorno aprile 7, 2026, <https://developers.googleblog.com/mediatek-npu-and-litert-powering-the-next-generation-of-on-device-ai/>
72. Hardware-Assisted Low-Latency NPU Virtualization Method for Multi-Sensor AI Systems, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/24/24/8012>
73. Hardware-Assisted Low-Latency NPU Virtualization Method for Multi-Sensor AI Systems, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC11679731/>
74. Sustainable Strides: How AI and Accelerated Computing Are Driving Energy Efficiency, accesso eseguito il giorno aprile 7, 2026, <https://blogs.nvidia.com/blog/accelerated-ai-energy-efficiency/>
75. An Analytical Model for Performance-Carbon Co-Optimization of Edge AI Accelerators - Lirias, accesso eseguito il giorno aprile 7, 2026, <https://lirias.kuleuven.be/retrieve/2a4ae44d-fe4a-459a-972f-c4cf3adca019>
76. Power Estimation and Energy Efficiency of AI Accelerators on Embedded Systems - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1996-1073/18/14/3840>