

Stato dell'Arte dei Modelli di Car-Following e Controllo del Traffico in Ambienti V2X: Dai Paradigmi Fisici all'Accelerazione Hardware AI e Neuromorfica

1. Introduzione e Fondamenti della Modellazione Microscopica del Flusso di Traffico

La modellazione del flusso di traffico rappresenta uno strumento analitico di importanza critica per la comprensione, la previsione e la valutazione dell'efficienza e della sicurezza dei sistemi di trasporto. All'interno di questo vasto dominio, la simulazione microscopica si distingue per la sua capacità di analizzare le dinamiche dei veicoli a livello individuale, riproducendo matematicamente le interazioni continue tra unità adiacenti.¹ Il nucleo centrale di qualsiasi simulatore microscopico (come SUMO, VISSIM o PARAMICS) è costituito dal modello di *car-following* (CF), un costrutto algoritmico progettato per descrivere il moto longitudinale di veicoli successivi che procedono all'interno della medesima corsia.³

L'evoluzione storica dei modelli di *car-following*, le cui radici risalgono agli studi pionieristici condotti da Reuschel nel 1950 e da Pipes nel 1953, ha attraversato decenni di progressi interdisciplinari, assorbendo concetti dall'ingegneria del traffico, dalla cinematica, dalla psicologia cognitiva e, più recentemente, dall'intelligenza artificiale (AI) e dalla teoria del controllo dei sistemi dinamici.¹ L'obiettivo fondamentale di questi modelli è stabilire una mappatura matematica tra gli stimoli ambientali percepiti dal conducente (o dai sensori del veicolo) — tipicamente la distanza relativa (*spacing*), la velocità del veicolo ospite e la differenza di velocità rispetto al veicolo che lo precede — e una conseguente azione di controllo, che si traduce in un comando di accelerazione o decelerazione.⁷

Con l'imminente transizione verso ecosistemi di trasporto caratterizzati da un'autonomia di livello 4 e 5 e dalla pervasività delle comunicazioni Vehicle-to-Everything (V2X), la validità dei modelli tradizionali è stata messa in discussione.⁸ I veicoli autonomi (AV) e i veicoli connessi e autonomi (CAV) non sono soggetti ai tempi di reazione biologici, all'affaticamento visivo o alle illusioni ottiche che affliggono i conducenti umani, e possiedono capacità di percezione che si estendono oltre la linea di vista (*Non-Line-of-Sight*, NLOS).¹⁰ Di conseguenza, l'industria e l'accademia stanno assistendo a un radicale cambio di paradigma: dal predominio dei modelli puramente analitici e basati sulla fisica, si sta passando a framework ibridi guidati dai dati, reti neurali informate dalla fisica (PINN), agenti basati sul Deep Reinforcement Learning (DRL) e

architetture neuromorfiche (SNN).⁶ Tale transizione algoritmica impone sfide computazionali senza precedenti, rendendo l'utilizzo di acceleratori hardware AI (come GPU, NPU, TPU e chip neuromorfici) non più un'opzione, ma un requisito stringente per l'esecuzione in tempo reale (real-time inference) a bordo veicolo (Edge Computing).¹³

2. Il Paradigma Cinematico: Il Modello di Newell e le Sue Limitazioni

Nel tentativo di descrivere matematicamente la cinematica del traffico veicolare, il modello semplificato di car-following proposto da G.F. Newell nel 1961 (e successivamente raffinato) ha rappresentato un punto di svolta fondamentale.⁶ Il modello di Newell appartiene alla categoria dei modelli stimolo-risposta ed è stato concepito con l'intento di fornire un framework analitico a basso ordine per descrivere la propagazione delle perturbazioni spaziotemporali all'interno di un flusso di traffico denso e omogeneo.¹⁶

2.1 Formulazione Matematica e Principi Operativi

Il costrutto teorico di Newell si fonda sull'assunto che, in condizioni di traffico congestionato, la traiettoria spaziotemporale di un veicolo inseguitore n sia essenzialmente una traslazione omogenea della traiettoria del veicolo che lo precede, identificato come $n - 1$.¹⁸

Matematicamente, se $x_n(t)$ denota la posizione del veicolo n al tempo t , il modello stabilisce che la traiettoria lineare a tratti del veicolo inseguitore è definita mediante uno spostamento spaziale e un ritardo temporale rispetto al leader.¹⁸

Questi parametri traslazionali corrispondono a due grandezze fisiche specifiche:

1. **Distanza di sicurezza spaziale (d_n):** Rappresenta il gap spaziale che il conducente desidera mantenere in condizioni di congestione, ed è intimamente legato alla distanza minima di arresto o *standstill spacing*.¹⁸
2. **Ritardo temporale (τ_n):** Equivale al tempo di reazione apparente o *time headway* desiderato dal conducente, che governa la latenza con cui l'inseguitore replica le variazioni di velocità del leader.¹⁸

2.2 Criticità e Limiti Strutturali del Modello di Newell

Nonostante la sua immensa utilità per la stima macroscopica delle emissioni e per la simulazione rapida delle onde di traffico causate da colli di bottiglia o semafori⁶, il modello di Newell presenta limitazioni stringenti quando applicato alla microsimulazione ad alta fedeltà o al controllo dei veicoli autonomi. Il modello originario manca di parametri legati alle differenze cognitive intrinseche dei conducenti e non è in grado di modellare dinamicamente le asimmetrie del comportamento umano; ad esempio, i conducenti reali reagiscono in modo

diverso alle fasi di accelerazione rispetto a quelle di decelerazione.¹ Inoltre, ignora completamente le interazioni multi-veicolo, caratteristiche dominanti negli ambienti V2X.³

3. Oltre Newell: Modelli Fisici e Dinamici Avanzati

Per superare le astrazioni del modello di Newell, l'ingegneria dei trasporti ha sviluppato famiglie di modelli più sofisticati, capaci di descrivere le accelerazioni continue in base alle leggi della dinamica e alle tolleranze psico-fisiche umane.

3.1 Il Modello di Sicurezza di Gipps e l'OVM

Il modello di Gipps si fonda su un principio di sicurezza assoluta, calcolando un'accelerazione basata sulla massima decelerazione del veicolo precedente.¹⁸ Tuttavia, il modello tende a produrre frenate brusche irrealistiche nella normale dinamica di flusso, limitandone l'applicabilità nello sviluppo di logiche di controllo per il comfort dei passeggeri dei CAV.¹ L'Optimal Velocity Model (OVM) postula invece che ogni conducente cerchi costantemente di adattare la propria velocità a una "velocità ottimale" dipendente dalla distanza dal veicolo precedente.¹ Pur permettendo agili analisi di stabilità lineare, l'OVM classico è inadatto come controller a bordo dei CAV perché genera accelerazioni fisicamente impossibili ad alte velocità.¹⁹

3.2 L'Intelligent Driver Model (IDM): Lo Standard Aureo Deterministico

L'Intelligent Driver Model (IDM) formula un'equazione di accelerazione continua che integra il desiderio di raggiungere una velocità di crociera e la necessità di mantenere un gap dinamico.¹

A differenza dell'OVM, l>IDM include esplicitamente la differenza di velocità Δv per implementare una strategia di frenata intelligente, capace di operare in sicurezza anche a velocità elevate e di differenziare la decelerazione di comfort da quella di emergenza.¹

4. Ambienti V2X e l'Evoluzione del Controllo del Traffico

La percezione del veicolo nei sistemi tradizionali (Line-of-Sight, LOS) è limitata al leader immediato.¹⁰ Il V2X crea un ecosistema cooperativo (Non-Line-of-Sight, NLOS) in cui i veicoli scambiano ad alta frequenza messaggi di sicurezza di base (BSM) comprendenti coordinate GPS, vettori di velocità e input di accelerazione.¹⁰

4.1 Cooperative Adaptive Cruise Control (CACC)

Mentre un sistema ACC basato sull>IDM reagisce ai cambiamenti del leader con un ritardo fisico, il CACC utilizza i collegamenti V2V (Vehicle-to-Vehicle) per formare plotoni di veicoli sincronizzati.²⁴ La condivisione dei profili di accelerazione permette di attenuare l'effetto dei disturbi in direzione a monte del flusso di traffico, assicurando la stabilità di stringa (string

stability).²⁵

4.2 La Latenza di Rete

Ritardi V2X superiori a 1.0 secondo compromettono l'efficacia del CACC, innescando ampie oscillazioni.²¹ L'industria sta implementando il Cellular-V2X (C-V2X), basato sugli standard 3GPP LTE/5G, che impiega la comunicazione diretta V2V a bassissima latenza per mitigare il packet loss e stabilizzare i controllori.²⁵

5. Modelli Guidati dai Dati, DRL e Architetture Ibride (PINN)

5.1 Deep Reinforcement Learning (DRL)

In un framework DRL (come DDPG o TD3), un agente apprende massimizzando una funzione di ricompensa personalizzata, ponderando deviazione di velocità, *jerk* (comfort) ed efficienza dei consumi.¹⁸ Integrati con reti Seq2Seq per prevedere le incertezze di movimento, gli algoritmi DRL superano i conducenti umani in termini di rapidità di smorzamento delle onde di traffico.¹⁸

5.2 Physics-Informed Neural Networks (PINNs)

Il paradigma del Physics-Informed Deep Learning per il Car-Following (PIDL-CF) fonde i modelli basati sulla fisica (IDM) e le reti neurali.¹² La Loss function viene arricchita con un termine di regolarizzazione che misura la discrepanza tra l'accelerazione predetta dalla rete neurale e l'accelerazione fisicamente coerente calcolata dal modello cinematico.⁷ Questo garantisce un'eccezionale efficienza dei dati (addestramento stabile anche con dati scarsi) e una sicurezza predittiva superiore in reti ibride.¹²

6. Il Collo di Bottiglia Computazionale: CPU, GPU e NPU

Un veicolo autonomo deve completare il ciclo decisionale del modello di car-following con tolleranze di latenza estreme (≈ 33 millisecondi per frame a 30 FPS). Se l'inferenza ritarda, la stabilità CACC collassa.¹³

Le CPU tradizionali sono inadeguate di fronte al calcolo tensoriale massivo, raggiungendo throughput critici e latenze inaccettabili.¹³ Le GPU (es. NVIDIA DRIVE Orin) superano altre piattaforme nelle operazioni matriciali dense e parallele, capaci di erogare prestazioni fino a 254 TOPS per chip,³⁶ ma incontrano l'ostacolo dell'alto assorbimento termico/energetico (fino a 60W per singolo nodo Edge).³⁸

Per conciliare controllo real-time sub-millisecondo e consumi ridotti (sotto i 10 Watt), sono emerse le **Neural Processing Units (NPU)** e le **Tensor Processing Units (TPU)**. Basate su architetture *Dataflow* con macro array di unità MAC (Multiply-Accumulate), le NPU minimizzano la latenza nei calcoli tensoriali V2X riducendola di quasi il 60% rispetto a GPU equivalenti,⁴⁰ con

costi energetici infinitesimali (0.7 - 1.2 mJ per inferenza, consumando tra i 2.5W e i 7.5W totali).¹³

7. La Frontiera Neuromorfica: Spiking Neural Networks (SNN) per il Car-Following

Nonostante i formidabili progressi garantiti da NPU e reti neurali profonde classiche (ANN), l'assorbimento energetico e la necessità di elaborare input continui impongono barriere progettuali per sistemi IoT veicolari su vasta scala. La più recente evoluzione architetturale per il controllo longitudinale autonomo è rappresentata dal salto verso il calcolo neuromorfico tramite le **Spiking Neural Networks (SNN)**.

7.1 Paradigma ed Efficienza delle SNN

Le Spiking Neural Networks, riconosciute come reti neurali di terza generazione, emulano strettamente le dinamiche dei neuroni biologici (come il modello Leaky Integrate-and-Fire, LIF). A differenza delle reti neurali artificiali standard, che comunicano aggiornando continuamente tensori con valori in virgola mobile e operano in modo sincrono, le SNN scambiano informazioni solo attraverso impulsi discreti e binari (spike) nel dominio del tempo.

La peculiarità delle SNN risiede nel paradigma *event-driven* (guidate dagli eventi): un neurone si attiva ed emette uno spike verso gli strati successivi solo quando il potenziale di membrana accumulato supera una determinata soglia. Ciò genera una "codifica sparsa", nella quale l'algoritmo sostituisce le gravose e dense moltiplicazioni matriciali (Multiply-Accumulate) con semplici operazioni di addizione (Accumulate), rimanendo in uno stato di riposo per la maggior parte del tempo. Il risultato è un'efficienza energetica estrema, essenziale per i veicoli autonomi o per le flotte di droni che cooperano tramite V2X, riducendo le latenze di trasmissione e il consumo di batteria di ordini di grandezza.

7.2 Modelli di Controllo Cognitivi (Akkumula) e DRL-SNN

Nell'ambito specifico del car-following, la natura asincrona delle SNN ha aperto la strada a una modellazione molto più aderente alla biologia del conducente umano. Un approccio all'avanguardia è costituito dal framework **"Akkumula"** (proposto da Alberto Morando, 2025), un modello di guida basato sulle Spiking Neural Networks che sfrutta la teoria dell'accumulazione dell'evidenza (Drift Diffusion Models). Invece di far calcolare a un'equazione

lo stato deterministico per ogni istante di tempo t , Akkumula impiega i neuroni spiking per simulare come un conducente reale accumuli input percettivi (ad esempio l'allargarsi o il restringersi del gap rispetto al leader) in modo graduale. Solo quando i segnali percettivi oltrepassano una certa soglia decisionale, viene attivato un aggiustamento netto del controllo motorio (frenata, accelerazione o sterzata). Integrato con librerie moderne come PyTorch e SpikingJelly, questo modello riproduce fedelmente i tempi di reazione umani e la gestione dinamica del gap, potendo essere addestrato su dataset reali in tempi brevi tramite l'ottimizzazione del gradiente surrogato.

Simultaneamente, la teoria delle SNN è stata fusa con i controlli CACC e il Reinforcement Learning in agenti di **Deep Reinforcement Learning con codifica di popolazione**. In contesti V2X, recenti proposte impiegano modelli DRL basati su SNN per ottimizzare l'allocazione delle risorse di comunicazione e la stabilità longitudinale nei sistemi Integrated Sensing and Communication (ISAC), fornendo l'agilità computazionale necessaria per riadattare istantaneamente il fascio di comunicazione senza collassare sotto sforzo.

7.3 Architetture End-to-End (SAD) e Hardware Neuromorfico

Oltre ai singoli moduli di controllo, l'approccio neuromorfico si sta espandendo all'intera pipeline dell'auto a guida autonoma. Ricerche recenti hanno presentato **Spiking Autonomous Driving (SAD)**, la prima SNN unificata progettata per affrontare i tre pilastri della guida: percezione, previsione e pianificazione del percorso.

SAD processa flussi di telecamere multi-vista per generare visioni a volo d'uccello spazio-temporali, utilizza una via neurale spiking per stimare le interazioni future tra i veicoli e, nel modulo di pianificazione (che incorpora la logica di car-following), genera sequenze di traiettorie sicure e comode, rispettando le leggi della fisica veicolare (evitando collisioni). Addestrato e testato sul benchmark *nuScenes*, SAD ha dimostrato prestazioni comparative alle CNN classiche ma con il massiccio vantaggio del risparmio energetico.

Per manifestare appieno questi vantaggi, le SNN richiedono hardware progettato su misura: i processori neuromorfici nativi (come **Intel Loihi 2**, **BrainChip Akida**, o **SpiNNaker**).

Questi chip supportano elaborazioni asincrone senza ricadere nel collo di bottiglia della memoria (Von Neumann bottleneck). Un esempio concreto della superiorità architetturale è il modello **CarSNN**, un algoritmo convoluzionale spiking ottimizzato per classificare vetture nel traffico urbano in combinazione con fotocamere a eventi (Dynamic Vision Sensors, DVS). Eseguito direttamente sul processore Intel Loihi, CarSNN è in grado di prendere decisioni dinamiche con una **latenza massima sub-millisecondo (0.72 ms)**, consumando una potenza irrisoria di appena **310 mW**. Tale efficienza rende l'accelerazione hardware SNN il candidato definitivo per il mantenimento di stringhe CACC altamente compresse in ecosistemi V2X saturi.

8. Conclusioni

La teoria del car-following si è evoluta dalle astrazioni deterministiche e lineari del modello di Newell e dalla rigidità di sistemi come l'Optimal Velocity Model (OVM) a configurazioni dinamiche sofisticate (IDM). Di fronte alle limitazioni umane, l'avvento degli ambienti V2X ha permesso la sincronizzazione dei veicoli in plotoni (CACC), spingendo tuttavia al limite l'infrastruttura comunicativa a causa delle latenze di rete.

Il paradigma ibrido delle Physics-Informed Neural Networks (PINN) si è imposto come l'architettura risolutiva in tale ambito, abbinando il pragmatismo matematico delle equazioni IDM come termine di regolarizzazione alla flessibilità percettiva delle reti neurali.

Tuttavia, l'ingestione di queste reti in un contesto reale impone l'abbandono delle obsolete CPU

in favore di potenti GPU o più efficienti NPU in configurazione Edge Computing.

L'apice di questa corsa all'efficienza è oggi incarnato dalle **Spiking Neural Networks (SNN)**. Tramite modelli cognitivi come Akkumula e architetture olistiche come Spiking Autonomous Driving (SAD), supportate da acceleratori neuromorfici dedicati (es. Intel Loihi), il settore sta dimostrando che è possibile gestire la fluidodinamica del traffico e le latenze V2X scendendo sotto il millisecondo e risparmiando frazioni immense di energia. Il passaggio verso questo calcolo asincrono delineerà la mobilità sostenibile e reattiva delle smart city del futuro.

Bibliografia

1. Car-Following Models for Human-Driven Vehicles and Autonomous Vehicles: A Systematic Review | Journal of Transportation Engineering, Part A - ASCE Library, accesso eseguito il giorno aprile 7, 2026, <https://ascelibrary.org/doi/10.1061/JTEPBS.TEENG-7836>
2. Microscopic Traffic Flow Models: a survey for mixed autonomous vehicles flow, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/394951390_Microscopic_Traffic_Flow_Models_a_survey_for_mixed_autonomous_vehicles_flow
3. An extended car-following model considering backward-looking effect: A machine learning approach - Canadian Science Publishing, accesso eseguito il giorno aprile 7, 2026, <https://cdnscepub.com/doi/10.1139/cjce-2023-0018>
4. Automatic Calibration of Microscopic Traffic Simulation Models Using Artificial Neural Networks - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/23/21/8798>
5. Advancements in accident-aware traffic management: a comprehensive review of V2X-based route optimization - PMC, accesso eseguito il giorno aprile 7, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12508076/>
6. Car-Following Models: A Multidisciplinary Review - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2304.07143v5>
7. A Physics-Informed Generative Car-Following Model for Connected Autonomous Vehicles, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1099-4300/25/7/1050>
8. Autonomous Vehicles: Evolution of Artificial Intelligence and the Current Industry Landscape, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2504-2289/8/4/42>
9. Quantifying the Impact of Cellular Vehicle-to- everything (C-V2X) on Transportation System Efficiency, Energy and Environment - Morgan State University, accesso eseguito il giorno aprile 7, 2026, <https://www.morgan.edu/Documents/ACADEMIA/CENTERS/ntc/umec/UMEC-Final%20report%20051%20-%20C-V2X%20Research.pdf>
10. Evaluating V2X-Based Vehicle Control under Unreliable Network Conditions, Focusing on Safety Risk - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2076-3417/14/13/5661>
11. Comparing driving behavior of humans and autonomous driving in a professional

- racing simulator - PMC, accesso eseguito il giorno aprile 7, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7857611/>
12. A Physics-Informed Deep Learning Paradigm for Car-Following Models - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/pdf/2012.13376>
 13. NPU vs. CPU: Edge AI Benchmarks for Real-Time Vision - Silex Technology, accesso eseguito il giorno aprile 7, 2026,
<https://www.silextechnology.com/unwired/npu-vs-cpu-object-detection-benchmarks>
 14. The acceleration of artificial intelligence in automotive. - Ambarella, accesso eseguito il giorno aprile 7, 2026,
<https://www.ambarella.com/blog/the-acceleration-of-ai-in-automotive/>
 15. A car-following model with the consideration of vehicle-to-vehicle communication technology - ResearchGate, accesso eseguito il giorno aprile 7, 2026,
https://www.researchgate.net/publication/298815615_A_car-following_model_with_the_consideration_of_vehicle-to-vehicle_communication_technology
 16. Energy Efficiency of Connected Autonomous Vehicles: A Review - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/12/19/4086>
 17. file_177-summits-24-4-uluslararası-akilli-ulasim-sistemleri-zirvesi-bildiriler-kitabi-70.pdf - AUS TÜRKİYE, accesso eseguito il giorno aprile 7, 2026,
https://austurkiye.org.tr/uploads/dosyalar/file_177-summits-24-4-uluslararasi-akilli-ulasim-sistemleri-zirvesi-bildiriler-kitabi-70.pdf
 18. Car-Following Models: A Multidisciplinary Review - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2304.07143v4>
 19. The Car-Following Model and Its Applications in the V2X Environment: A Historical Review, accesso eseguito il giorno aprile 7, 2026,
<https://www.mdpi.com/1999-5903/14/1/14>
 20. Comparison of Vehicle Dynamics of Microscopic Car Following Models: Optimal Velocity and Intelligent Driver Model - ResearchGate, accesso eseguito il giorno aprile 7, 2026,
https://www.researchgate.net/publication/323400960_Comparison_of_Vehicle_Dynamics_of_Microscopic_Car_Following_Models_Optimal_Velocity_and_Intelligent_Driver_Model
 21. An enhanced optimal velocity model for car-following with connected and autonomous vehicles - OAE Publishing Inc., accesso eseguito il giorno aprile 7, 2026, <https://www.oaepublish.com/articles/ces.2025.60>
 22. A Hardware-in-the-Loop V2X Simulation Framework: CarTest - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/1424-8220/22/13/5019>
 23. Real-Time Distributed Cooperative Adaptive Cruise Control Model Considering Time Delays and Actuator Lag | Request PDF - ResearchGate, accesso eseguito il giorno aprile 7, 2026,
https://www.researchgate.net/publication/360694382_Real-Time_Distributed_Cooperative_Adaptive_Cruise_Control_Model_Considering_Time_Delays_and_Actuator_Lag
 24. A data-driven behavior generation algorithm in car-following scenarios -

- Carnegie Mellon University Robotics Institute, accesso eseguito il giorno aprile 7, 2026, https://www.ri.cmu.edu/app/uploads/2019/04/IAVSD_248.pdf
25. (PDF) Practical Challenges in CACC Communication: ITS G5, LTE Uu, and LTE Sidelink PC5 - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/357549137_Practical_Challenges_in_CA_CC_Communication_ITS_G5_LTE_Uu_and_LTE_Sidelink_PC5
 26. Decentralized Control Framework for Optimal Platoon Spacing and Energy Efficiency - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/14/1/169>
 27. Adapting Time Headway in Cooperative Adaptive Cruise Control to Network Reliability - Clemson University, accesso eseguito il giorno aprile 7, 2026, https://people.computing.clemson.edu/~jmarty/papers/ieee_tvt_final_version.pdf
 28. Robust H_{∞} MPC method for heterogeneous CACC system with communication delay, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/391387682_Robust_H_MPC_method_for_heterogeneous_CACC_system_with_communication_delay
 29. Experimental V2X Evaluation for C-V2X and ITS-G5 Technologies in a Real-Life Highway Environment | Request PDF - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/356398166_Experimental_V2X_Evaluation_for_C-V2X_and_ITS-G5_Technologies_in_a_Real-Life_Highway_Environment
 30. Vehicle-to-Everything Cooperative Perception for Autonomous Driving - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2310.03525v5>
 31. A Deep Reinforcement Learning Approach for Efficient, Safe and Comfortable Driving, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2076-3417/13/9/5272>
 32. Deep Reinforcement Learning Car-Following Control Based on Multivehicle Motion Prediction - MDPI, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-9292/13/6/1133>
 33. Fast and Accurate Prediction of Vehicle Dynamics using Physics-Informed Neural Networks - TechRxiv, accesso eseguito il giorno aprile 7, 2026, <https://www.techrxiv.org/users/867892/articles/1250938/master/file/data/vehicle-pinns/vehicle-pinns.pdf>
 34. A physics-informed deep learning paradigm for car-following models - ResearchGate, accesso eseguito il giorno aprile 7, 2026, https://www.researchgate.net/publication/353120353_A_physics-informed_deep_learning_paradigm_for_car-following_models
 35. Choosing the Right AI Accelerator | NPU or TPU for Edge and Cloud Applications, accesso eseguito il giorno aprile 7, 2026, <https://www.gateworks.com/choosing-the-right-ai-accelerator-npu-or-tpu-for-edge-and-cloud-applications/>
 36. The New Era of Transportation Is Built on NVIDIA DRIVE Orin, accesso eseguito il giorno aprile 7, 2026, <https://blogs.nvidia.com/blog/new-era-transportation-drive-orin/>
 37. NVIDIA Orin SoC Analysis for ADAS - aivon, accesso eseguito il giorno aprile 7,

2026,

<https://www.aivon.com/blog/automotive-electronics/nvidia-orin-soc-analysis-for-adas/>

38. What to Know About AI Hardware Accelerators: NPUs, TPUs, and Beyond - HP, accesso eseguito il giorno aprile 7, 2026, <https://www.hp.com/us-en/shop/tech-takes/ai-hardware-accelerators-npu-tpu-gpu-guide>
39. Top 15 Edge AI Chip Makers with Use Cases in 2026 - AIMultiple, accesso eseguito il giorno aprile 7, 2026, <https://aimultiple.com/edge-ai-chips>
40. Benchmarking Edge AI Platforms for High-Performance ML Inference - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2409.14803v1>
41. Lightweight Transformer Architectures for Edge Devices in Real-Time Applications - arXiv, accesso eseguito il giorno aprile 7, 2026, <https://arxiv.org/html/2601.03290v1>
42. Performance and Efficiency Gains of NPU-Based Servers over GPUs for AI Model Inference, accesso eseguito il giorno aprile 7, 2026, <https://www.mdpi.com/2079-8954/13/9/797>