

Comparazione Globale (ANN vs SNN vs FSNN)

Questo confronto evidenzia come l'evoluzione verso la FSNN abbia risolto i compromessi storici tra accuratezza matematica, consumo energetico e adattabilità temporale.

Metrica / Caratteristica	ANN (Artificial Neural Network)	SNN V5 (Standard Spiking Po2)	FSNN V5.1 (Hardware-Aware ALIF)
Paradigma di Calcolo	Spaziale / Matrice Continua	Spazio-Temporale (Spike costanti)	Spazio-Temporale Adattivo (ALIF)
Operazioni Logiche	Moltiplicazioni Floating-Point (MAC/DSP)	Somme e Bit-Shift	Somme e Bit-Shift (Zero DSP)
Costo Energetico	Estremo (Tutti i neuroni calcolano sempre)	Basso (Spike binari sparsi)	Minimo Assoluto (Sparsità omeostatica)
Gestione del Tempo	Nessuna (Amnesia totale tra frame)	Accumulatore semplice (Inerzia lunga)	Dinamica fluida (Ritardi sinaptici + Fatica)
Gestione del Cambio Scena	Immediato (ma senza contesto)	Lento ("Fantasma temporale" del vecchio input)	Immediato (I neuroni stanchi cedono il passo)
Fattibilità su FPGA	Molto complessa (Richiede molti DSP)	Ottima	Eccellente (Zero divisioni, solo logica)

			intera/shift)
--	--	--	---------------

Sintesi Analitica:

- L'ANN è una "fotocamera istantanea": perfetta per immagini statiche, ma insostenibile per flussi video continui su hardware a basso consumo (Edge Computing/Aerospazio).
- La SNN V5 è stata il primo passo: efficiente energeticamente, ma troppo rigida. Un neurone eccitato dal target "A" continuava a sparare anche quando appariva il target "B", sporcando la classificazione.
- La FSNN è un sistema biologico artificiale. Introducendo la "fatica neurale" (Omeostasi) e le distanze fisiche (Ritardi), la rete impara a bilanciare le proprie risorse. Se un neurone lavora troppo, si alza la sua soglia e si "spegne" da solo, abbattendo drasticamente il numero di spike totali e permettendo un cambio di decisione fulmineo.

DOCUMENTAZIONE TECNICA ARCHITETTURALE

FSNN (Full Spiking Neural Network) - Hardware-Aware ALIF

Versione: 5.1 (Ottimizzata per sintesi FPGA/ASIC)

1. Filosofia del Design

La FSNN è un'architettura neurale spiking profonda progettata con un vincolo ingegneristico assoluto: **la totale assenza di moltiplicatori hardware (DSP) e circuiti divisori continui**. Ogni meccanismo biologico complesso (come la plasticità, l'inibizione e la memoria) è stato tradotto in operazioni matematiche elementari compatibili con la logica digitale di base (Somme, Sottrazioni e Scorrimenti di Bit).

2. Anatomia del Layer Nascosto (ALIF Layer)

Il cuore pulsante della FSNN è il layer *ALIF (Adaptive Leaky Integrate-and-Fire)*. Rispetto a un neurone artificiale standard, questo strato implementa 4 dimensioni dinamiche:

A. Ritardo Sinaptico (Delay Buffer)

Nel cervello, gli impulsi impiegano tempo per viaggiare lungo gli assoni in base alla loro lunghezza.

- **Funzionamento:** A ogni sinapsi (connessione tra pixel e neurone) è assegnato un ritardo fisso (es. da 0 a 3 tick). L'input non viene processato istantaneamente in blocco.
- **Implementazione Hardware:** Realizzato tramite un *Ring Buffer* (o Shift Register su FPGA). La matrice dei pesi "pesca" i dati storici utilizzando maschere binarie, allineando temporalmente pattern spaziali che arrivano in momenti diversi.

B. Quantizzazione in Potenze di Due (Po2 Quantization)

Per azzerare il costo energetico del calcolo tensoriale, la rete non usa numeri in virgola mobile per i pesi.

- **Funzionamento:** Durante l'addestramento, una funzione (Quantization-Aware Training) costringe i pesi ad assumere solo valori che siano potenze di 2 (es. 2^{-1} , 2^{-2} , 2^{-3}). Viene imposta una soglia di hard-sparsity: i pesi inferiori a 2^{-5} vengono brutalmente troncati a zero.
- **Vantaggio Hardware:** Un prodotto tra l'input (che è uno spike binario 1 o 0) e un peso Po2 si risolve in un semplice accumulo condizionato. Non serve alcun moltiplicatore.

C. Inibizione Laterale Low-Rank (WTA)

I neuroni comunicano tra loro per sopprimersi a vicenda (*Winner-Takes-All*), garantendo che solo il neurone più sicuro "parli" all'output.

- **Funzionamento:** Utilizza due matrici compresse (rec_U e rec_V) quantizzate in Po2. Quando un neurone spara, invia un segnale negativo ai suoi vicini, abbassando il loro potenziale di membrana e zittendo il rumore di fondo.

D. Omeostasi Locale (La "Fatica" Neurale)

È la caratteristica distintiva della FSNN. Risolve il problema del "Fantasma Temporale" senza usare onerose divisioni globali.

- **Funzionamento:** La soglia di attivazione del neurone non è fissa. È composta da una Soglia Base + un valore di Fatica. Ogni volta che il neurone emette uno spike, la sua Fatica sale, rendendo più difficile il prossimo sparo. Se riposa, la Fatica decade.
- **Effetto sul Flusso:** Quando l'input cambia (es. si passa dal numero 7 al 2), i neuroni che leggevano il 7 sono così "stanchi" che si spengono quasi immediatamente, permettendo ai neuroni freschi del 2 di prendere il controllo in pochissimi tick di clock.

3. Dinamica dell'Integrazione (I "Leak" Hardware)

I neuroni biologici dimenticano col tempo. Nelle reti neurali standard si usano costanti di

decadimento (es. $V = V \times 0.8$). Nella FSN, si usano approssimazioni esatte tramite **Bit-Shift**:

- **Decadimento del Potenziale:** $V = V - (V \gg 3)$. Equivale a sottrarre $1/8$ del valore, mantenendo la memoria reattiva.
- **Recupero dalla Fatica:** $F = F - (F \gg 3)$. Garantisce che il neurone torni fresco abbastanza velocemente per reagire a stimoli prolungati.

4. Il Livello di Uscita (Leaky Integrator)

L'ultimo strato della FSN differisce dal layer nascosto perché **non spara spike**.

- **Scopo:** Accumula gli impulsi rari e sparsi provenienti dal layer ALIF, creando un "Potenziale di Fiducia" continuo e leggibile dall'esterno.
- **Stabilità:** Utilizza un decadimento molto più lento ($V = V - (V \gg 4)$), ovvero perde solo $1/16$ a tick). Questa grande inerzia garantisce che, nonostante gli spike del layer precedente siano rari per colpa della fatica, la decisione finale rimanga stabile e non oscilli.

5. Metodologia di Addestramento (BPTT e Gradienti Surrogati)

A causa della non derivabilità degli spikes, La FSN non può essere addestrata con la classica Backpropagation spaziale. Le tecniche utilizzare sono:

1. **Surrogate Gradient:** Poiché il gradino generato dallo spike (0 o 1) ha derivata nulla, in fase di *backward* la FSN utilizza una 'pseudo-derivata' morbida (approssimazione), permettendo a PyTorch di calcolare il gradiente e di conseguenza come aggiustare i pesi.
2. **Spike-Timing-Dependent Plasticity (STDP):** Si tratta di un metodo non supervisionato e locale. Il peso di una sinapsi viene calcolato guardando solo il tempo relativo tra lo spike del neurone precedente e quello successivo.

Possibilità:

-**LTP** (Long-Term Potentiation): Se il neurone pre-sinaptico spara appena prima di quello post-sinaptico, la sinapsi si rafforza (causalità).

-**STD** (Long-Term Depression): Se il neurone pre-sinaptico spara subito dopo quello post-sinaptico, la sinapsi si indebolisce.

Ciò elimina la necessità di un'unità centrale che coordini l'apprendimento, tuttavia è difficile scalarlo per reti profonde (instabile)

Riepilogo per la Sintesi Hardware (FPGA/ASIC)

- **Moltiplicazioni (DSP):** 0
- **Divisioni logiche:** 0
- **Dati Memoria:** Interi (Fixed-Point)
- **Operazioni necessarie:** Somme, Sottrazioni, Operatori Logici (AND per le maschere), Scorrimenti (Shift).

REPORT SULLA SCALABILITÀ E COMPLESSITÀ COMPUTAZIONALE

Analisi Comparativa: ANN Continuo vs SNN (Standard) vs FSNN (ALIF Hardware-Aware)

1. Complessità Computazionale (Time Complexity)

La differenza fondamentale tra le reti tradizionali e le reti spiking risiede nel passaggio da un calcolo **Denso (Dense Computing)** a un calcolo **Guidato dagli Eventi (Event-Driven Computing)**.

Sia N_{in} il numero di neuroni di input e N_{out} il numero di neuroni nel layer successivo. Per semplicità, assumiamo $N_{in} \approx N_{out} = N$.

- **ANN (Artificial Neural Network): $O(N^2)$**
 - L'ANN esegue una moltiplicazione matrice-vettore completa a ogni tick temporale, indipendentemente dal contenuto dell'immagine. Ogni neurone in ingresso deve essere moltiplicato per ogni peso. Il tempo di esecuzione scala quadraticamente rispetto alle dimensioni della rete.
- **SNN V5 (Standard Spiking): $O(S \times N)$**
 - Nella SNN, l'aggiornamento avviene *solo* se il neurone in ingresso emette uno spike. Chiamiamo S il numero totale di spike attivi ($S \ll N$). La complessità scende drasticamente a $O(S \times N)$. Se la rete ha una sparsità del 90% (solo il 10% dei neuroni spara), la SNN esegue il 90% di operazioni in meno rispetto all'ANN.
- **FSNN V5.1 (ALIF Hardware-Aware): $O(S(t) \times N)$ con $S(t) \rightarrow 0$**
 - La FSNN possiede la stessa complessità base $O(S \times N)$ della SNN, ma introduce la **Sparsità Adattiva nel Tempo**. Grazie alla "fatica neurale" (Omeostasi), il numero di spike $S(t)$ non è costante, ma **decade rapidamente verso lo zero** una volta che l'informazione è stata elaborata.
 - *Risultato:* A regime, la FSNN salta interi cicli di clock perché $S \approx 0$, portando la complessità operativa media ad avvicinarsi a $O(1)$ per lunghi tratti del flusso video, riattivandosi a $O(S \times N)$ solo durante i cambi di scena.

2. Efficienza Energetica e Hardware (ALU & DSP)

L'efficienza reale su silicio (ASIC/FPGA) non si misura solo in Big-O, ma nel *tipo* di operazione eseguita.

Architettura	Tipo di Operazione (ALU)	Costo Energetico Relativo	Necessità di DSP Hardware

ANN	Moltiplicazione e Accumulo (MAC) 32-bit Float	100% (Baseline)	Alta (Collo di bottiglia)
SNN V5	Somma Intera (Add) + Bit-Shift (Decadimento)	~5%	Zero
FSNN V5.1	Somma Intera + Sottrazione + Bit-Shift	~1% - 2%	Zero

Il Vantaggio della FSNN:

Eliminando la divisione (sostituita dai Bit-Shift del tipo $V - (V \gg 3)$ per i decadimenti e l'omeostasi locale) e utilizzando pesi quantizzati in potenze di 2 (2^k), la FSNN non richiede alcun blocco DSP (Digital Signal Processor). Tutto il routing logico viene risolto da semplici sommatore e registri, riducendo il consumo di milliwatt a livelli ottimali per l'Edge Computing.

3. Complessità Spaziale e Memoria (Space Complexity)

L'estrema efficienza di calcolo della FSNN richiede un compromesso (Trade-off) sul fronte della memoria. Il tempo e lo spazio fisico per l'hardware neuromorfico sono interconnessi.

- **ANN: $O(N^2)$ Pesi.**
 - Nessuna memoria di stato. Serve solo la RAM per salvare la matrice dei pesi.
- **SNN V5: $O(N^2)$ Pesi + $O(N)$ Stati.**
 - Richiede memoria aggiuntiva per mantenere il potenziale di membrana (V) e l'ultimo spike emesso di ogni neurone.
- **FSNN V5.1: $O(N^2)$ Pesi + $O(N)$ Stati + $O(N_{in} \times D_{max})$ Buffer**
 - **La Sfida della FSNN:** Per simulare il Ritardo Sinaptico (Delay), la FSNN richiede un Ring Buffer grande quanto il numero di input moltiplicato per il ritardo massimo (D_{max}). Inoltre, deve mantenere in memoria la variabile di Fatica (F) per ogni neurone.
 - **Soluzione Hardware:** Sebbene la complessità spaziale sia maggiore, su FPGA questo si traduce nell'uso massiccio di **BRAM (Block RAM)** o registri a scorrimento, risorse generalmente abbondanti e a bassissimo consumo rispetto ai moltiplicatori attivi.

4. Scalabilità su Larga Scala (Es. 10^6 Neuroni)

Cosa succede se passiamo dall'analisi di piccole immagini (MNIST) all'elaborazione di segnali

radar complessi o video ad alta risoluzione?

1. **Collasso dell'ANN:** Scalare un'ANN a milioni di neuroni richiede GPU server massicce. La latenza diventa inaccettabile a causa del limite di banda della memoria (il "Memory Wall"), poiché ogni peso deve essere caricato e moltiplicato a ogni frame.
2. **Saturazione della SNN:** Una SNN standard scala linearmente bene, ma in scenari molto grandi e rumorosi rischia l'**Iperattività**. Senza meccanismi di controllo, un rumore in ingresso può causare una tempesta di spike a catena, paralizzando il bus di comunicazione dell'hardware (Routing Congestion).
3. **La Robustezza della FSNN:** La FSNN scala in modo **perfetto**. Grazie all'ALIF (Adaptive Leaky Integrate-and-Fire), la rete è **auto-regolante**. In una rete di 1 milione di neuroni, la fatica locale assicura che, statisticamente, solo una microscopica frazione della rete possa sparare simultaneamente. Questo garantisce che il traffico dati sui bus del chip FPGA rimanga costantemente al di sotto della soglia critica, prevenendo la saturazione indipendentemente dalla dimensione del network.

Fine Documento.