

CF_FSNN — Harness_SNN_IIDM: validazione in anello chiuso e caratterizzazione hardware (Fase B2.0 · T7)

Il Verilog generato del controllore composto — rete spiking, allineamento e legge di controllo — provato bit-esatto rispetto al blocco in ANELLO CHIUSO su 99 scenari di car-following con cut-in, e il sistema completo implementato, misurato in clock, risorse ed energia, e portato a bitstream.

Oggetto: blocco composto Donatello_SNN_IIDM = SNN Donatello_Tier@BALANCED (nfrac 13) + allineamento align + controllore ACC-IIDM. Ingressi s, v, dv, v_l; uscita accel.

Livelli di fedeltà: simulazione RTL in anello chiuso e simulazione di netlist post-place&route in Vivado xsim; sintesi e implementazione reali su xc7z020; energia da attività di commutazione registrata (SAIF). NON è una misura su silicio — quella è la Fase C.

Grounding: questo documento è GENERATO da uno script che LEGGE gli artefatti (t7_results.mat, metrics.json, sweep.json, netlist.json, power.json, power_params.json, saif_stats.json e i report Vivado grezzi). Nessun numero è trascritto a mano, con una sola eccezione dichiarata nel §5.1. I cancelli sono deterministici (esito 0/N); le grandezze non misurabili con questo flusso sono marcate come STIMA e mai presentate come misura.

Riproducibilità: bash FaseB2.0/Harness_SNN_IIDM/hw/run_harness_snniidm_hw.sh [stadio] — un comando per stadio, con cancello di provenienza sui sorgenti caratterizzati.

Sommario


1. Sintesi	4
2. Oggetto e perimetro	6
2.1 Il blocco composto	6
2.2 `align`: una inferenza per control-step	6
2.2 La rete, la variante e la quantizzazione	6
2.3 I cinque parametri, e cosa significano	7
2.4 Cosa è dentro e cosa è fuori	7
3. Il problema della validazione in anello chiuso	8
3.1 Perché un confronto diretto non basta	8
3.2 La decomposizione in due prove disgiunte	8
3.3 Il riferimento è il blocco, e un golden monolitico non lo è	8
3.4 Tre termini di paragone distinti, e a cosa serve ciascuno	9
4. Validazione in anello chiuso a livello RTL	10
4.1 I cancelli	10
4.2 Metriche dal motore canonico	10
Sicurezza (17 metriche)	10
Comfort (7 metriche)	11
Inseguimento (5 metriche)	11
Efficienza e stabilità (2 metriche)	11
4.3 Un caso limite reale: il congelamento a parametri ripetuti	12
5. Dal blocco al sistema	14
5.1 Il processore legge ciò che il blocco calcola	14
5.2 La netlist dopo place&route	14
6. Frequenza e risorse	15
6.1 Due numeri distinti, e come si leggono	15
6.2 Fuori contesto e nel sistema sono perimetri diversi	16
6.3 Risorse e costo dell'allineamento	16
6.4 Margine sul control-step	17
7. Energia nel funzionamento reale	18
7.1 La finestra attiva si misura, non si assume	18
7.2 L'inattività è stazionaria, e lo si è provato	18
7.3 Gli otto carichi reali	18
7.4 Energia per passo di controllo, misurata e non composta	19

8. Quando il sommario nasconde la misura	21
9. Bitstream e provenienza	22
9.1 Riproducibilità	22
10. Osservazioni di metodo	23
10.1 Il numero che lo strumento stampa non è quello che si crede di leggere	23
10.2 Un cancello che non può fallire non è un cancello	23
10.3 Misurare il costo prima di impegnare le ore	23
10.4 Il debito si paga sui numeri, non sul tempo	23
11. Limiti dichiarati	24
12. Conclusioni	25
Riferimenti	26
Artefatti del progetto	26
Strumenti	26

1. Sintesi

Questo documento riporta la validazione e la caratterizzazione del controllore completo destinato all'FPGA: il blocco composto che dai quattro stati di car-following — distanza, velocità propria, velocità relativa e velocità del veicolo che precede — produce direttamente l'accelerazione comandata, passando per una rete neurale spiking che stima i parametri del modello di guida e per la legge di controllo che li usa.

La domanda a cui il documento risponde è una sola: il codice che finirà sull'FPGA si comporta come il blocco progettato, e a quale costo? La risposta è affermativa su ogni cancello, e i costi sono misurati.



Copertura dei cancelli di equivalenza. Ogni barra è un confronto contro il blocco di riferimento, e ogni esito è zero disallineamenti. La scala è logaritmica: i quattro cancelli coprono perimetri di ampiezza molto diversa, e il più stretto — la netlist — è dichiarato tale, non nascosto.


Grandezza	Valore	Natura
RTL == blocco in anello chiuso (T7-EXACT)	0 su 58 522 confronti, 99 scenari	misurato
Plant del banco == riferimento (PLANT-PAR, senza DUT)	0 disallineamenti su 99 scenari	misurato
Parametri letti dal processore via AXI == blocco	0 su 58 522, in entrambe le configurazioni di gating	misurato
Netlist post-place&route == blocco	0 su 1 507 (3 scenari dichiarati)	misurato
Collisioni AGGIUNTIVE rispetto all'oracolo	0 (RTL 3, oracolo 3)	misurato
Frequenza di clock deployabile	40 MHz (WNS +0.022 ns, WHS +0.033 ns)	misurato
Limite del cammino critico	41.1 MHz	derivato (da WNS a vincolo stretto)
Risorse post-place&route	8453 LUT · 4556 FF · 69 DSP · 1 BRAM	misurato
Inferenza / margine sul control-step 0.1 s	13.9 μ s / $\approx$ 7 200×	derivato
Energia DINAMICA per control-step	1.10 mJ (al duty reale, 0.0146 %)	misurato, non composto
Energia statica del dispositivo per control-step	10.3 mJ	misurato — pavimento del chip, tenuto SEPARATO
Clock gating: commutazione in idle	da 26.0 a 2.0 toggle per clock (13×	misurato nel SAIF
Clock gating: guadagno in watt	non ottenuto	NON misurabile con questo flusso
Bitstream PYNQ-Z1	prodotto, WNS e utilizzo identici a quelli caratterizzati	artefatto

Nota. Tre grandezze non sono state ottenute, e il documento lo dice dove servirebbero: il guadagno in watt del clock gating (§8), il caso peggiore energetico (§7.3) e l'equivalenza della netlist su tutti i 99 scenari (§5.2). Per ciascuna è indicato il motivo e il costo che avrebbe avuto ottenerla.

2. Oggetto e perimetro

2.1 Il blocco composto

Il dispositivo sotto esame non è la rete neurale da sola, ma la catena completa che porta dagli stati misurati al comando di accelerazione. È composta di tre parti in cascata: la rete spiking, che stima cinque parametri del modello di guida; un blocco di allineamento; e la legge di controllo ACC-IIDM, che dai parametri e dagli stati calcola l'accelerazione.



Confine di misura: tutto ciò che sta nel riquadro chiaro è implementato in PL e caratterizzato in T7b

Il blocco composto dietro il wrapper AXI4-Lite, e il sistema che lo ospita. Il riquadro chiaro delimita ciò che è implementato in logica programmabile e caratterizzato in questo documento; il processore e il convertitore di protocollo sono il contorno con cui il blocco deve convivere.

2.2 `align`: una inferenza per control-step

Il blocco di allineamento non è un dettaglio implementativo: è ciò che rende corretto il comportamento dell'anello. La rete produce i cinque parametri con una latenza rispetto agli ingressi fisici; se il controllore li ricevesse appena pronti, vedrebbe due transizioni per ogni passo di controllo — una quando cambiano gli stati e una quando arrivano i parametri — e il filtro interno che stima l'accelerazione del veicolo che precede verrebbe aggiornato due volte. Il risultato sarebbe più veloce e sbagliato.

`align` trattiene i quattro ingressi fisici finché i cinque parametri non cambiano, poi li rilascia insieme: un solo fronte, una sola inferenza, un solo aggiornamento del filtro per control-step. Il costo di questa correttezza è misurato in §6.3.

Nota. Questo è un punto in cui una modifica plausibile ha prodotto un difetto reale durante lo sviluppo. Un tentativo di accelerare il blocco registrando le uscite all'esterno di `align` guadagnava frequenza ma reintroduceva il doppio fronte: più veloce, e con l'anello che si comportava diversamente. Da allora ogni modifica al confine è soggetta a un cancello che conta i fronti e ne pretende esattamente uno.

2.2 La rete, la variante e la quantizzazione

Tre nomi ricorrono nel documento e vanno sciolti, perché identificano scelte di progetto già fatte e qui soltanto ereditate.

No me	Che cosa indica
rete a spike	una rete ricorrente a 32 neuroni nascosti che, per ogni passo di controllo, evolve per 10 passi interni; la ricorrenza è fattorizzata a rango 16 e i ritardi sinaptici arrivano a 6 passi. Produce 5 uscite, i parametri del §2.3. In hardware i 32 neuroni condividono una sola unità di calcolo, percorsa a turno: è ciò che tiene l'area entro il dispositivo
`Tie r@B ALA NCE D`	la rete è disponibile in tre varianti di pipelining — area minima, compromesso, margine temporale massimo. Qui è in uso la intermedia. Le tre varianti calcolano la stessa funzione: cambiano quanti registri separano gli stadi, quindi area e frequenza, non il risultato
`nfr ac 1 3`	i bit frazionari della rappresentazione in virgola fissa interna alla rete. Tredici bit dopo la virgola; la scelta viene da uno studio di quantizzazione dedicato, esterno a questo documento

2.3 I cinque parametri, e cosa significano

La rete non produce direttamente l'accelerazione: stima cinque parametri del modello di guida IDM, che la legge di controllo poi usa insieme agli stati misurati. Sono la velocità desiderata in strada libera, il tempo di via libera desiderato, la distanza minima da fermo, l'accelerazione massima confortevole e la decelerazione confortevole.

Parametro	Significato	Unità
v0	velocità desiderata in strada libera	m/s
T	tempo di via libera desiderato rispetto al veicolo che precede	s
s0	distanza minima da fermo	m
a	accelerazione massima confortevole	m/s ²
b	decelerazione confortevole	m/s ²

Sono questi cinque valori che il blocco di allineamento tratta, che il cancello PARAM-RANGE verifica entro i limiti del decodificatore, e la cui ripetizione produce il comportamento descritto nel §4.3.

Grandezza	Rappresentazione	Risoluzione	Intervallo
ingressi (distanza, velocità, velocità relativa, velocità del leader)	virgola fissa con segno, 32 bit di cui 20 frazionari	circa 1e-6	circa ±2048
uscita (accelerazione comandata)	virgola fissa con segno, 13 bit di cui 8 frazionari	1/256 = 0,0039 m/s ²	da -16,0 a +15,996 m/s ²

L'intervallo dell'uscita copre con margine la decelerazione fisica massima considerata dal modello di valutazione, 9 m/s², quindi la rappresentazione non satura nei casi di interesse.

2.4 Cosa è dentro e cosa è fuori

Il passo di controllo di 0.1 s non è una convenzione di comodo: è il passo temporale del dataset di riferimento, cioè la cadenza a cui il controllore è chiamato a decidere, 10 volte al secondo. È anche l'unico requisito temporale che il sistema deve rispettare: tutto il resto — frequenza di clock, latenza, duty — è caratterizzazione.

Dentro il perimetro	Fuori dal perimetro
Il Verilog generato dal blocco composto, simulato in xsim	Il comportamento su silicio (Fase C)
Il wrapper AXI4-Lite e il sistema con processore e convertitore	Il software applicativo sul processore
Sintesi, place&route e analisi statica dei tempi reali	La validazione del modello di guida in sé
Energia da attività di commutazione registrata (SAIF)	La misura di corrente su scheda
99 scenari di car-following con cut-in, in anello chiuso	Scenari non rappresentati nel dataset

3. Il problema della validazione in anello chiuso

3.1 Perché un confronto diretto non basta

Validare un componente in anello aperto è semplice: si danno gli stessi ingressi al codice e al riferimento e si confrontano le uscite. In anello chiuso questo non si può fare, perché gli ingressi del passo successivo dipendono dall'uscita del passo corrente: due implementazioni che divergono di un solo bit al passo k ricevono ingressi diversi al passo $k+1$, e da lì in poi il confronto non misura più l'equivalenza ma l'accumulo della divergenza.

Un confronto diretto fra le due traiettorie complete risponderebbe quindi a una domanda diversa da quella che interessa — «quanto divergono?» invece di «il codice è il blocco?» — e non permetterebbe di distinguere un difetto del codice da una differenza del modello di ambiente.

3.2 La decomposizione in due prove disgiunte

La validazione è stata quindi scomposta in due prove che non condividono il componente che l'altra verifica, ciascuna delle quali è un confronto in anello aperto e quindi deterministico.

Le due prove non condividono il componente che l'altra verifica

PLANT-PAR — il plant del banco e' quello di riferimento

T7-EXACT — l'RTL e' il blocco, sugli ingressi ricevuti



nessun DUT nell'anello: si prova SOLO il plant



nessun plant nel confronto: si prova SOLO il DUT

Le due prove. A sinistra il plant del banco viene confrontato con il modello di riferimento senza alcun DUT nell'anello, alimentandolo con la sequenza di accelerazioni registrata. A destra il DUT viene confrontato con il blocco sugli ingressi che ha effettivamente ricevuto, senza che il plant partecipi al confronto. Insieme coprono l'anello; separatamente, ciascuna è esatta.

Prova	Cosa verifica	Cosa NON contiene	Esito
PLANT-PAR	il modello di ambiente del banco è quello di riferimento	il DUT	0 su 99 scenari
T7-EXACT	l'RTL riproduce il blocco sugli ingressi ricevuti	il plant	0 su 58 522 confronti

3.3 Il riferimento è il blocco, e un golden monolitico non lo è

Il termine di paragone di ogni cancello è il blocco composto eseguito in simulazione, non una sua riscrittura. La distinzione ha avuto conseguenze concrete: un golden costruito estraendo il codice di un blocco precedente, ormai deprecato, si è rivelato non equivalente al composto — 385 scarti su 600 passi di controllo. Il difetto non era nell'RTL, ma nel riferimento.

Nota. Il controllo che avrebbe dovuto intercettarlo era passato, perché verificava il golden sugli stessi sei passi di controllo su cui era stato tarato: verificava la premessa su cui era costruito. Da allora il riferimento è il blocco stesso, guidato sugli ingressi che l'RTL ha davvero ricevuto.

3.4 Tre termini di paragone distinti, e a cosa serve ciascuno

Nel documento compaiono tre entità diverse. Confonderle rende ininterpretabile ogni numero, quindi vengono nominate qui una volta per tutte.

Entita	Che cos e	A che domanda risponde
il blocco	il modello Simulink `Donatello_SNN_IIDM`, eseguito in simulazione	è il RIFERIMENTO DI EQUIVALENZA: il codice generato si comporta come il blocco progettato?
l'RTL (e a valle la netlist, e il sistema con processore)	ciò che finira' sull'FPGA, nelle sue tre forme successive	è l'OGGETTO della validazione
l'oracolo	un controllore IDEALE: la stessa legge IIDM in forma analitica, alimentata con i parametri VERI di ciascuno scenario invece che con quelli stimati dalla rete	è la BASELINE DI QUALITA': quanto si perde stimando i parametri invece di conoscerli?

Nota. La distinzione è sostanziale. L'equivalenza col blocco è una proprietà binaria e si prova bit per bit: o coincide o no. Il confronto con l'oracolo non è un cancello e non ha un valore atteso di zero: misura quanto costa, in qualità di guida, il fatto che i parametri siano stimati da una rete anziché noti. Un divario lì non è un difetto dell'implementazione.

Ne segue una domanda legittima: perché le metriche non confrontano l'RTL con il blocco, visto che il blocco viene eseguito in Simulink proprio per fare da riferimento? Perché quel confronto sarebbe degenerare per costruzione. Il cancello T7-EXACT stabilisce che l'accel prodotta dall'RTL coincide con quella del blocco a ogni passo di controllo, su tutti i 58 522 confronti; il modello di ambiente è deterministico; quindi, a parità di stato iniziale, le due traiettorie coincidono passo per passo e ogni metrica calcolata su di esse assume lo stesso valore. Calcolarle separatamente produrrebbe due colonne identiche. Il confronto informativo è quello con l'oracolo, ed è quello riportato.

4. Validazione in anello chiuso a livello RTL

4.1 I cancelli

Sui 99 scenari del dataset esaustivo, 600 passi di controllo ciascuno, i cancelli danno:

Cancello	Domanda	Perimetro	Esito
PLANT-PAR	il plant del banco è quello di riferimento?	99 scenari	0 disallineamenti
T7-EXACT	l'RTL è il blocco?	58 522 confronti	0 disallineamenti
PARAM-RANGE	i cinque parametri stanno nei limiti del decodificatore?	58 522 passi	0 fuori dominio
T7-SAFE	l'RTL provoca collisioni che l'oracolo non ha?	99 scenari	0 collisioni aggiuntive

Le 3 collisioni osservate sono le stesse per l'RTL e per l'oracolo: derivano da manovre di inserimento aggressive presenti nel dataset, non dall'implementazione. Il cancello di sicurezza non chiede che non ci siano collisioni, chiede che l'hardware non ne aggiunga.

La campagna completa — 99 scenari, 600 passi di controllo ciascuno, una simulazione per scenario — dura 60 minuti.

Nota. Perché 58 522 confronti e non 59 400. Novantanove scenari da 600 passi ne darebbero 59 400. I tre scenari che collidono terminano però in anticipo, perché la simulazione si ferma all'impatto: contribuiscono 922 passi invece di 1 800, cioè 878 in meno. Il totale riportato è la somma effettiva dei passi eseguiti, non un arrotondamento, ed era stato dichiarato prima della campagna.

I cancelli sono stati provati sensibili, cioè li si è visti fallire su dati deliberatamente alterati: alterando di un solo bit meno significativo un valore di riferimento, T7-EXACT segnala esattamente un disallineamento; forzando un parametro fuori dominio, PARAM-RANGE lo rileva; e il rilevatore di ripetizione scatta su cinque parametri identici ma non su quattro. Un cancello che non si è mai visto fallire non è un cancello.

4.2 Metriche dal motore canonico

Per ciascuno dei 99 scenari sono calcolate 31 metriche di comportamento e sicurezza. Il punto metodologico è che le metriche non provengono da una simulazione separata: sono calcolate sulle serie prodotte dall'RTL durante la validazione, con lo stesso motore di valutazione usato per il modello di riferimento. Prova e metrica insistono così sullo stesso perimetro.

La tabella che segue riporta tutte e 31 le metriche, aggregate sui 99 scenari. La regola di aggregazione è dichiarata per famiglia e non è la mediana: sulla sicurezza conta la coda, e una mediana su 99 scenari cancellerebbe proprio lo scenario peggiore, che è l'unico che interessa. Per le grandezze di tipo minimo si riporta il minimo, per quelle di tipo massimo e per le frazioni di violazione il massimo, per le restanti la media.

Sicurezza (17 metriche)

Metrica	Che cosa misura	Unità	Aggr.	RTL	Oracolo	Rapporto
TED_drac	Tempo esposto a DRAC oltre soglia	s	max	1.300	1.300	1.000
TET	Tempo esposto a TTC sotto soglia (Time Exposed TTC)	s	max	1.100	1.200	0.917
TID_drac	Tempo integrato dell'eccesso di DRAC	m/s ² x s	max	26.303	819.268	0.032
TIT	Tempo integrato del deficit di TTC (Time Integrated TTC)	s ²	max	1.277	1.333	0.958
brake_margin_min	Margine di evitabilità fisica	m	min	-3.790	-3.877	0.978
collided	Scenari con collisione	conteggio	somma	3	3	1.000
cpi	Crash Potential Index	-	media	0.000858	0.000873	0.983

Metrica	Che cosa misura	Unità	Aggr.	RTL	Oracolo	Rapporto
frac_drac_critical	Frazione di tempo con DRAC critico	-	max	0.026	0.026	1.000
frac_ttc_below_1.0	Frazione di tempo in avvicinamento con TTC sotto 1,0 s	-	max	1	1	1.000
frac_ttc_below_1.5	Frazione di tempo in avvicinamento con TTC sotto 1,5 s	-	max	1	1	1.000
frac_ttc_below_2.0	Frazione di tempo in avvicinamento con TTC sotto 2,0 s	-	max	1	1	1.000
frac_ttc_below_3.0	Frazione di tempo in avvicinamento con TTC sotto 3,0 s	-	max	1	1	1.000
impact_dv	Velocità relativa all'impatto (severità)	m/s	max	7.632	7.688	0.993
max_DRAC	Decelerazione massima richiesta per evitare la collisione	m/s ²	max	165.334	8.08e+03	0.020
min_gap	Distanza minima paraurti-paraurti	m	min	-0.387	-0.536	0.721
min_time_headway	Distanza temporale minima (s/v)	s	min	0.0068	0.000156	43.743
min_ttc	Tempo minimo alla collisione (TTC)	s	min	0.017	0.000389	44.889

Comfort (7 metriche)

Metrica	Che cosa misura	Unità	Aggr.	RTL	Oracolo	Rapporto
frac_accel_iso_viol	Frazione con accelerazione oltre il limite ISO	-	max	0	0	—
frac_decel_iso_viol	Frazione con decelerazione oltre il limite ISO	-	max	0.055	0.060	0.917
frac_jerk_uncomf	Frazione di tempo con jerk scomodo	-	max	0.290	0.554	0.524
max_abs_jerk	Jerk massimo in valore assoluto	m/s ³	max	90.625	90	1.007
max_decel	Decelerazione più forte	m/s ²	max	9	9	1.000
rms_accel	Accelerazione efficace (RMS)	m/s ²	media	0.800	0.844	0.949
rms_jerk	Jerk efficace (RMS)	m/s ³	media	1.989	1.804	1.102

Inseguimento (5 metriche)


Metrica	Che cosa misura	Unità	Aggr.	RTL	Oracolo	Rapporto
mean_T_pred	Tempo di via libera desiderato, medio, predetto dalla rete	s	media	1.400	1.249	1.121
mean_abs_dv_ss	Velocità relativa media a regime	m/s	media	0.982	0.923	1.064
mean_abs_gap_err_ss	Errore di distanza medio a regime	m	media	4.675	4.093	1.142
mean_time_gap	Distanza temporale media (s/v)	s	media	2.266	2.085	1.087
rms_gap_error	Errore di distanza efficace (RMS)	m	media	9.442	8.374	1.127

Efficienza e stabilità (2 metriche)

Metrica	Che cosa misura	Unità	Aggr.	RTL	Oracolo	Rapporto
energy_proxy	Proxy di energia: integrale della potenza specifica positiva	m ² /s ²	media	52.914	63.327	0.836
string_stability	Guadagno di stabilità di stringa	-	media	0.767	0.787	0.974

Nota. Su alcune metriche il rapporto è molto lontano da uno. Non è un segnale sulla qualità dell'implementazione: il caso peggiore su tutti gli scenari è dominato dai 3 che collidono, dove il tempo alla collisione tende a zero e la decelerazione richiesta diverge — per l'RTL e per l'oracolo, che collidono negli stessi scenari. In quel regime il rapporto smette di misurare l'implementazione e misura la patologia dello scenario. Il confronto discriminante è quello del §4.3.

Le metriche vengono dalle serie PRODOTTE DALL'RTL, non da una simulazione a parte



Due metriche di sicurezza, RTL contro oracolo, uno scenario per punto. La diagonale è l'uguaglianza. Gli scostamenti sono la conseguenza del comportamento descritto in §4.3, non di un errore di calcolo: l'equivalenza bit-esatta è già stabilita dal cancello T7-EXACT.

Nota. Due valori che sembrano errori e non lo sono. La distanza minima risulta negativa: è la convenzione del motore di valutazione, che non satura la distanza a zero proprio per poter misurare di quanto una collisione è avvenuta — un valore negativo è una compenetrazione. E le frazioni di tempo con tempo alla collisione sotto soglia valgono 1 su tutte e quattro le soglie: significa che esiste almeno uno scenario in cui, per tutta la durata dell'avvicinamento, il tempo alla collisione resta sotto i 3 secondi. Sono i medesimi scenari che collidono, e valgono 1 anche per l'oracolo.

Nota. Una domanda a cui questo documento NON risponde: quanto sono accurati i cinque parametri stimati dalla rete rispetto ai valori veri. È la validazione del modello, non della sua implementazione, ed è stata svolta in fasi precedenti del progetto. Qui l'accuratezza della rete entra solo indirettamente, attraverso il confronto con l'oracolo del §4.2: quel divario e' il costo della stima, misurato sull'esito che conta, cioè la qualità di guida.

4.3 Un caso limite reale: il congelamento a parametri ripetuti

Il blocco è sensibile al fronte: riparte quando i suoi ingressi cambiano. Quando la rete produce due volte di seguito gli stessi cinque parametri, `align` rilascia valori identici, nessun fronte viene generato e l'accelerazione resta al valore precedente per quel passo.

Grandezza	Valore
Passi di controllo con i cinque parametri ripetuti	15 494 su 58 522 (26.5 %)
Frazione di quelli in cui l'accelerazione resta ferma	100 %
Collisioni aggiuntive che ne derivano	0

L'impatto sulla sicurezza si misura confrontando RTL e oracolo sui soli scenari che hanno subito congelamenti (46 su 99): è lì che l'effetto, se c'è, deve manifestarsi. Il confronto è fatto sul rapporto delle mediane.

Metrica	RTL	Oracolo	Rapporto
min_ttc	1.802	1.844	0.977
max_DRAC	2.149	2.008	1.070
min_gap	2.578	2.319	1.112
min_time_headway	1.384	1.512	0.915

Gli scostamenti sono di pochi punti percentuali e di segno opposto fra loro — il tempo alla collisione peggiora del 2.3 %, la distanza minima migliora dell'11.2 % — il che indica una perturbazione, non una degradazione sistematica. E le collisioni aggiuntive restano 0.

Nota. È una diagnostica, non un difetto: l'RTL riproduce il blocco esattamente (T7-EXACT è 0), quindi il comportamento è quello progettato. Va però conosciuto, perché a valle si traduce in un'accelerazione che si aggiorna meno spesso di quanto il control-step suggerirebbe. L'effetto sulle metriche di sicurezza è quantificato nella tabella qui sopra e non produce collisioni aggiuntive.

5. Dal blocco al sistema

5.1 Il processore legge ciò che il blocco calcola

Il cancello precedente prova che il Verilog è il blocco. Non prova che il processore, scrivendo gli ingressi e leggendo il risultato attraverso il bus, ottenga lo stesso valore: fra i due ci sono il wrapper, il protocollo, il contatore di latenza e il gating del clock. La cosim AXI colma questo tratto, guidando il sistema completo dal lato del processore.

Configurazione	Confronti	Disallineamenti
gating del clock disattivo	58 522	0
gating del clock attivo (configurazione di deployment)	58 522	0

Le due configurazioni sono la stessa netlist: il gating è comandato da un bit di registro, non da un parametro di compilazione. Il confronto isola così l'effetto del gating invece di confrontare due circuiti diversi.

Nota. Nota di provenienza: questi due esiti sono gli unici numeri di questo documento che non vengono letti a macchina da un artefatto strutturato — provengono da `COSIM\_AXI.md`, che registra la run del 2026-07-31 (76 minuti, 198 simulazioni). Tutti gli altri numeri sono letti dai file `.json`, `.mat` e `.rpt` citati in copertina.

5.2 La netlist dopo place&route

L'ultimo tratto è fra il Verilog e la netlist piazzata e instradata: la rete di celle reali del dispositivo. La simulazione a livello di porte cattura inizializzazione e propagazione degli indefiniti, che la simulazione RTL non vede.

Grandezza	Valore
Scenari (sottoinsieme dichiarato)	1, 4, 9
Confronti	1 507
Disallineamenti	0
Costo rispetto alla simulazione comportamentale	44× (misurato su questo progetto)
Costo che avrebbero i 99 scenari completi	≈ 28 ore

Scenario	Passi	Disallineamenti	Durata	s / passo
1	600	0	16 m 31 s (include compilazione)	1.65
4	600	0	15 m 43 s	1.57
9	307	0	10 m 15 s	2.00

Il sottoinsieme è dichiarato in anticipo e comprende uno scenario che collide, cioè con la serie più corta: è il caso che aveva scoperto un difetto del banco durante lo sviluppo, quando il confronto leggeva oltre la fine dei dati di riferimento. Il totale atteso — 1 507 confronti — era stato dichiarato prima della esecuzione, e torna: se non fosse tornato, un esito di zero disallineamenti non sarebbe stato credibile, perché un banco che confronta meno passi del previsto produce zero disallineamenti proprio perché non guarda.


Nota. Questo cancello è un conferma su N dichiarato, non la base di una metrica: con 28 ore di costo per la copertura completa, l'estensione a tutti gli scenari è stata esclusa sul costo misurato, e il limite è scritto qui invece che taciuto.

6. Frequenza e risorse

Due grandezze ricorrono in questa sezione. Lo slack di setup (WNS, worst negative slack) è il margine temporale del cammino combinatorio peggiore: quanto tempo avanza, nel ciclo di clock, dopo che il segnale più lento è arrivato. Se è negativo il circuito non funziona a quella frequenza. Lo slack di hold (WHS) è il margine opposto: il segnale non deve arrivare troppo PRESTO, prima che il registro di destinazione abbia campionato il valore precedente; un hold negativo non si corregge rallentando il clock, ed è quindi un difetto più insidioso.

6.1 Due numeri distinti, e come si leggono

La frequenza di un progetto su FPGA non è un numero solo. Sono due, e confonderli porta a dichiarare prestazioni che il sistema non ha.



Slack peggiore in funzione della frequenza ottenuta. Il punto più alto che chiude è la frequenza deployabile; il limite del cammino critico si legge invece al punto più stretto, dove il vincolo forza lo strumento a ottimizzare al massimo, anche se lì il timing non chiude.

Chiesta [MHz]	Ottenuta [MHz]	Periodo [ns]	WNS [ns]	WHS [ns]	LUT	FF	Chiude
15	15.152	66.000	+30.749	+0.022	8416	4556	si
20	20.000	50.000	+16.097	+0.052	8405	4556	si
25	25.000	40.000	+9.519	+0.037	8412	4556	si
30	30.303	33.000	+2.764	+0.045	8408	4556	si
35	34.484	28.999	+1.008	+0.026	8404	4556	si
40	40.000	25.000	+0.022	+0.033	8453	4556	si
45	45.455	22.000	-2.470	+0.048	8483	4560	no
50	50.000	20.000	-4.355	+0.023	8503	4562	no

Grandezza	Valore	Natura
Frequenza deployabile	40 MHz (WNS +0.022 ns, WHS +0.033 ns)	misurato: il più alto fra i provati che chiude
Limite del cammino critico	41.1 MHz	derivato: 1/ritardo al punto più stretto (50 MHz), che NON chiude

Anche lo slack di hold è stato letto e non supposto: è positivo in tutti i punti, quindi il criterio di chiusura è leggibile sul solo setup. Un progetto che chiude il setup ma viola il hold non è deployabile, e la differenza non si vede se non si guarda.

Nota. Il processore quantizza la frequenza richiesta: su 4 degli 8 punti provati la frequenza ottenuta differisce da quella chiesta (15 → 15.152 MHz, 30 → 30.303 MHz, 35 → 34.484 MHz, 45 → 45.455 MHz). Il periodo di clock non è quindi l'inverso della frequenza richiesta, e va letto dalla tabella dei clock del report. Una tabella costruita sull'assunzione contraria aveva 4 righe sbagliate su 8.

6.2 Fuori contesto e nel sistema sono perimetri diversi

La stessa logica può essere implementata da sola — fuori dal contesto del sistema — oppure dentro il sistema completo. I due risultati non sono intercambiabili, e in questo progetto la differenza è netta: a 40 MHz il sistema completo chiude con uno slack di +0.022 ns, mentre la stessa logica implementata fuori contesto non chiude, con -0.194 ns.



Lo stesso circuito, alla stessa frequenza, chiude nel sistema completo e non chiude nell'implementazione fuori contesto. La stima fuori contesto è qui la più pessimista: ne segue che un numero ottenuto in quel modo non è una capacità del progetto ed è confrontabile solo con altri numeri dello stesso perimetro.


Nota. Ne discende anche che una regolarità osservata su un altro blocco di questo stesso progetto — per cui la frequenza deployabile valeva circa metà di quella fuori contesto — non vale qui: quella proporzione dipendeva dal fatto che il cammino critico passasse dal confine d'ingresso, il che su questo blocco non accade più.

6.3 Risorse e costo dell'allineamento

Risorsa	Occupazione	Frazione del dispositivo
LUT	8453	15.9 %
Flip-flop	4556	4.3 %
DSP	69	31.4 %
Blocchi di memoria	1	0.7 %

La risorsa più impegnata è il DSP, al 31.4 %; nessuna è vicina alla saturazione. La ripartizione interna mostra dove finisce l'area, e in particolare quanto costa la correttezza discussa in §2.2.

Istanza	Ruolo	LUT	FF	DSP	RAMB18
`sys_wrapper`	sistema completo	8453	4556	69	2
`tier0`	IP AXI (wrapper + blocco)	8084	4097	69	2
`u_dut`	il blocco composto	7974	3794	69	2
`u_Tier`	↳ SNN Tier@BAL/n13	4077	2442	52	2
`u_SNN`	↳ rete a spike	2735	2045	36	2
`u_DEC`	↳ decodifica del readout	950	397	16	0
`u_ACC`	↳ controllore ACC-IIDM	3032	1100	17	0
`u_align`	↳ allineamento	876	252	0	0
`ps7_axi_periph`	convertitore di protocollo (contorno)	352	426	0	0



Ripartizione delle risorse dentro il blocco, dopo place&route. Il blocco di allineamento non è logica gratuita: costa 876 LUT, il 11 % del blocco. È il prezzo di una sola inferenza per passo di controllo, cioè della correttezza del filtro interno.

Nota. Perché allora 40 MHz e non meno? Con un margine di oltre settemila volte sul passo di controllo, qualunque punto dello sweep soddisfa il requisito, e i più lenti risparmierebbero energia dinamica. La frequenza riportata è il massimo dimostrato, non una scelta di deployment: caratterizzare il limite superiore serve a sapere quanto margine esiste per lavoro futuro sullo stesso blocco. La scelta della frequenza di esercizio è una decisione di sistema, e alla luce di questi dati può essere presa guardando al consumo invece che alle prestazioni.

6.4 Margine sul control-step

Il solo requisito temporale del sistema è il passo di controllo, 0.1 s. L'inferenza completa dura 555 cicli di clock.

Grandezza	Valore
Durata dell'inferenza a 40 MHz	13.9 μ s
Passo di controllo	0.1 s
Margine	$\approx 7\,200\times$
Finestra effettivamente occupata (protocollo incluso)	582 cicli = 14.5 μ s
Duty	0.0146 %

Nota. I due numeri di duty che compaiono negli artefatti misurano cose diverse e non sono in contraddizione: 555 cicli è la latenza pura del blocco — la sua capacità — mentre 582 è la finestra effettivamente occupata dal sistema, protocollo di bus incluso. Per l'energia vale il secondo, ed è quello usato in §7.

7. Energia nel funzionamento reale

7.1 La finestra attiva si misura, non si assume


Un passo di controllo non dura quanto la latenza del blocco: ci sono anche le scritture sul bus e l'attesa del segnale di completamento. La finestra è stata quindi derivata dal banco stesso (582 cicli, di cui 27 di protocollo) invece di essere posta uguale alla latenza. Il duty che ne risulta, 0.0146 %, è la frazione di tempo in cui il circuito lavora davvero.

7.2 L'inattività è stazionaria, e lo si è provato

Perché una misura di potenza in inattività abbia senso, l'inattività deve essere uno stato stazionario: se il circuito avesse macchine a stati o contatori attivi, il valore dipenderebbe dalla finestra di osservazione. La verifica è stata fatta su tre finestre di ampiezza crescente.

Finestra [cicli]	Commutazioni (TC)	TC / ciclo
200	5200	26.0
1000	26000	26.0
5000	130000	26.0

Il rapporto è identico sulle tre finestre, che differiscono di un fattore 25. Con il gating attivo scende a 2.0 commutazioni per ciclo: è la misura del §8.



Tre letture che il sommario dei watt non permette. A sinistra: il numero di commutazioni per ciclo è costante su tre finestre che differiscono di un fattore 25, il che prova la stazionarietà. Al centro: il gating riduce la commutazione di 13 volte. A destra: gli otto carichi reali differiscono del 2.9 % in commutazione. Nessuna delle tre è visibile nei watt arrotondati.

Nota. La distinzione non è pedanteria. Tre valori di potenza uguali a tre decimali potrebbero esserlo anche per insensibilità dello strumento; un rapporto commutazioni/ciclo costante su un fattore 25 di durata, no. La premessa è verificata sul meccanismo, non dedotta dal risultato.

7.3 Gli otto carichi reali

La fase attiva è stata misurata su 8 carichi reali, uno per ciascuna combinazione di regime di guida e presenza di manovra di inserimento presente nel dataset. Sono otto e non nove: le combinazioni popolate sono state enumerate, non assunte. Ogni esecuzione della misura energetica ha anche confermato l'equivalenza funzionale sul proprio carico.

Carico	Regime	Dinamica [W]	Commutazioni (TC)	Disallineamenti
wl1	highway / senza inserimento	0.026	44252587	0
wl4	highway / con inserimento	0.026	43954392	0
wl28	urban / senza inserimento	0.026	43017937	0
wl31	urban / con inserimento	0.026	42973956	0
wl55	truck / senza inserimento	0.026	44189478	0
wl58	truck / con inserimento	0.026	43916965	0
wl73	mixed / senza inserimento	0.026	43492426	0
wl76	mixed / con inserimento	0.026	43201080	0


Grandezza	Valore
Potenza dinamica in inattività	0.011 W
Potenza dinamica mentre calcola	0.026 W
Dispersione fra gli otto carichi, nei watt	identici a tre decimali
Dispersione fra gli otto carichi, in commutazione	2.9 %

La dispersione fra i carichi non è nulla: vale 2.9 % in commutazione, che su 0.026 W corrisponde a circa 0.0008 W — cioè sotto la terza cifra decimale che lo strumento riporta. Dichiarare «dispersione nulla» significherebbe scambiare un limite di precisione per una proprietà del circuito.

Nota. Il caso peggiore energetico non è determinato. Si riporta il massimo osservato fra carichi reali, dichiarato come tale: un caso peggiore sintetico costruito su ipotesi di alta commutazione era stato provato sul blocco SNN da solo (rapporto T6, in Riferimenti) ed era risultato il più basso di tutti, quindi come limite superiore è stato smentito su misura. Individuare il regime peggiore richiederebbe uno studio dedicato.

7.4 Energia per passo di controllo, misurata e non composta

La tentazione naturale è comporre: potenza attiva per il duty, più potenza inattiva per il complemento. Quella composizione è stata confrontata con la misura diretta sul blocco SNN da solo (rapporto T6, in Riferimenti) e ha sottostimato di circa 1,6 volte, con lo scarto localizzato sui moltiplicatori. Qui i moltiplicatori sono di più. La misura è quindi stata fatta simulando un passo di controllo intero, senza comporre.



Le tre potenze dinamiche. Al duty reale il valore è dominato dall'inattività — per costruzione, dato che il circuito calcola per una frazione trascurabile del tempo. La statica del dispositivo resta separata perché è il pavimento del chip, non il costo del lavoro svolto.

Grandezza	Valore	Natura
Potenza dinamica al duty reale	0.011 W	misurato su un passo di controllo intero
Energia dinamica per passo di controllo	1.10 mJ	derivato dal precedente
Potenza statica del dispositivo	0.103 W	misurato — pavimento del chip
Energia statica per passo di controllo	10.3 mJ	derivato, tenuto SEPARATO
Copertura della registrazione di attività	12 506 su 19 951 reti = 62.7 %	misurato
Livello di confidenza dichiarato dallo strumento	High	misurato

La copertura va letta insieme ai watt: sul 37 % delle reti l'attività non proviene dalla registrazione ma dal modello interno dello strumento. È una proprietà della misura, non una nota a piè di pagina.

Nota. Un controllo indipendente conferma che la finestra di misura copre davvero un passo di controllo intero: il numero di commutazioni previsto dalla composizione dei due regimi — inattivo e attivo — differisce da quello registrato dell'1.5 %. È una verifica sui toggle, che nei watt sarebbe stata invisibile, perché a questo duty il valore è comunque dominato dall'inattività: una finestra sbagliata avrebbe prodotto un numero credibile.

8. Quando il sommario nasconde la misura

Il gating del clock è implementato e funziona: quando il blocco non lavora, il suo clock si ferma. La misura lo mostra senza ambiguità — la commutazione in inattività passa da 26.0 a 2.0 per ciclo, un fattore 13.

Nel sommario delle potenze, però, non si vede nulla: le due configurazioni riportano lo stesso valore. Non è una contraddizione, è un limite dello strumento, accertato sul blocco SNN da solo (rapporto T6, in Riferimenti) anche in negativo: la potenza delle reti di clock viene derivata dal vincolo di frequenza, non dall'attività registrata, e imporre attività nulla su quelle reti non cambiava il risultato. Qui il comportamento è riprodotto in modo indipendente, su un progetto diverso.

Nota. La conclusione onesta è quindi doppia: il gating agisce, e questo è misurato; il suo guadagno in watt non è ottenibile con questo flusso, e non viene stimato. Ottenerlo richiede un flusso diverso — la misura su scheda della Fase C, o un modello di potenza che accetti attività per singola rete di clock.

9. Bitstream e provenienza

Il sistema è stato portato a bitstream alla frequenza deployabile, con i file di consegna per la piattaforma. La costruzione del bitstream è un'esecuzione separata da quella che ha prodotto la caratterizzazione: che i due coincidano non è scontato e non è stato supposto.

Grandezza	Valore
Bitstream	4.05 MB, più i file di consegna della piattaforma
Slack peggiore	+0.022 ns — identico a quello caratterizzato
Risorse	identiche a quelle caratterizzate

Il confronto non è una verifica fatta una volta a mano: è un cancello eseguito a ogni rigenerazione della sintesi dei risultati, che si arresta se le due implementazioni divergono. Senza, una divergenza sarebbe invisibile guardando il solo bitstream.

9.1 Riproducibilità

Tutti i risultati si riproducono da un unico punto d'ingresso a stadi. Lo stadio di sintesi non esegue calcolo: riestrae i numeri dagli artefatti in pochi secondi, e dichiara gli artefatti mancanti invece di tacerli — un numero assente non deve somigliare a un numero verde.

La provenienza è garantita in forma di integrità dei file: la firma dei sorgenti caratterizzati è registrata e confrontata a ogni invocazione, e una differenza blocca gli stadi di calcolo. La forma alternativa — rigenerare il codice e confrontare — è stata scartata su verifica: il generatore non è deterministico sui nomi interni temporanei, quindi quel confronto fallirebbe sempre, anche a sorgenti identici.

10. Osservazioni di metodo

Le osservazioni che seguono non sono generalità: ciascuna corrisponde a un errore commesso e corretto durante questo lavoro, ed è documentata perché il costo di ri-commetterlo è alto.

10.1 Il numero che lo strumento stampa non è quello che si crede di leggere

Tre casi distinti in questo lavoro. Il processore quantizza la frequenza richiesta, quindi il periodo va letto e non calcolato. Il sommario delle potenze arrotonda a tre decimali, e sotto quella soglia la dispersione fra carichi sparisce. Le due implementazioni — fuori contesto e nel sistema — danno esiti opposti sullo stesso circuito alla stessa frequenza.

Nota. La regola che li riassume: quando un numero sembra troppo uniforme, troppo tondo o troppo comodo, si guarda l'artefatto sotto prima di spiegarlo. Una spiegazione tecnica plausibile per un dato sbagliato è più pericolosa di nessuna spiegazione.

10.2 Un cancello che non può fallire non è un cancello

Ogni cancello di questo lavoro è stato provato anche in negativo, su dati alterati deliberatamente: la firma dei sorgenti, la coerenza dei totali, la presenza della copertura di registrazione, la corrispondenza fra bitstream e sistema caratterizzato. In due casi il cancello ha intercettato un errore di chi scriveva, non del progetto — ed è precisamente il motivo per cui esiste.

Un controllo mal costruito è peggio di nessun controllo. Un audit dei formati di stampa, scritto per intercettare un difetto ricorrente, alla prima stesura contava come specificatore anche il segno di percentuale letterale, e mascherava così il difetto vero: un controllo con falsi positivi ne nasconde anche di reali.

10.3 Misurare il costo prima di impegnare le ore

Il passo più costoso di questa caratterizzazione — la misura al duty reale, quattro milioni di cicli — aveva un costo ignoto a priori, con una forbice fra le ipotesi ragionevoli di oltre un ordine di grandezza. Invece di stimarlo, è stato misurato su una finestra breve, estrapolato in modo deliberatamente pessimista e confrontato con un budget dichiarato.

Nella stessa direzione, una stima di costo scalata da un altro progetto si è rivelata pessimista di circa due volte: la simulazione di netlist era stata stimata in ottanta minuti e ne ha richiesti 42. Una stima portata da un contesto diverso è un ordine di grandezza, non una previsione.

10.4 Il debito si paga sui numeri, non sul tempo

Una costante misurata era stata riscritta a mano nel generatore del rapporto oltre che nello script che la produce. Nessuna delle due copie era sbagliata al momento della scrittura, ma la struttura permetteva a una misura futura di convivere in silenzio con un documento che ne stampa un'altra. La correzione — lo script scrive i parametri effettivamente usati, il generatore li legge — non ha migliorato alcun numero: ha eliminato un modo di sbagliare.

11. Limiti dichiarati

Domanda	Stato	Motivo
La netlist è equivalente su tutti gli scenari?	non provato — 3 dichiarati	costo misurato: $\approx$ 28 ore per la copertura completa
Qual è il caso peggiore energetico?	non determinato	si riporta il massimo osservato; il caso peggiore sintetico è stato smentito su misura
Quanto vale il gating in watt?	non misurabile con questo flusso	lo strumento deriva la potenza di clock dal vincolo, non dall'attività registrata
Il comportamento su silicio?	fuori perimetro	è l'oggetto della Fase C
La copertura della registrazione di attività?	62.7 % delle reti	sul resto vale il modello interno dello strumento

12. Conclusioni

Il controllore composto destinato all'FPGA è il blocco progettato, e lo è su ogni tratto della catena: dal Verilog al blocco in anello chiuso su 99 scenari, dal processore al blocco attraverso il bus in entrambe le configurazioni di gating, dalla netlist piazzata e instradata al blocco sul sottoinsieme dichiarato. Nessun cancello riporta un disallineamento, e nessuno di essi è stato accettato senza averlo prima visto fallire su dati alterati.

Il costo è misurato: 40 MHz deployabili con margine di 7 200 volte sul passo di controllo, 15.9 % delle LUT e 31.4 % dei DSP del dispositivo, 1.10 mJ di energia dinamica per passo di controllo. Il sistema è stato portato a bitstream, e il bitstream è lo stesso sistema su cui i numeri sono stati misurati.

Ciò che resta aperto è dichiarato: il guadagno in watt del gating, il caso peggiore energetico, l'equivalenza della netlist oltre il sottoinsieme scelto. Per ciascuno è indicato il motivo per cui non è stato ottenuto e il costo che avrebbe avuto ottenerlo — perché un limite scritto è una informazione, mentre un limite taciuto è un errore in attesa.

Riferimenti

Artefatti del progetto

Artefatto	Contenuto
`FaseB2.0/Harness_SNN_IIDM/results/RESULTS.md`	validazione in anello chiuso (T7a): cancelli e metriche
`FaseB2.0/Harness_SNN_IIDM/results/RESULTS_HW.md`	sintesi della caratterizzazione hardware (T7b)
`FaseB2.0/Harness_SNN_IIDM/results/SWEEP_FCLK.md`	frequenza, risorse post-route, perimetri
`FaseB2.0/Harness_SNN_IIDM/results/NETLIST.md`	simulazione della netlist post-place&route
`FaseB2.0/Harness_SNN_IIDM/results/POWER.md`	energia, commutazione e copertura
`FaseB2.0/Harness_SNN_IIDM/results/COSIM_AXI.md`	cosim dal lato processore
`document/HDL_PHASE.md` §6, §9	stato della fase e trappole verificate
`report/B2_0_HARNESS_SNN_REPORT.{md,pdf}`	rapporto sul blocco SNN da solo (Fase B2.0 · T6)

Strumenti

Strumento	Uso
Vivado 2026.1 (`xsim`, `synth_design`, `report_power`)	simulazione, implementazione, analisi
MATLAB R2026a con HDL Coder	generazione del Verilog dal blocco
xc7z020clg400-1 (PYNQ-Z1)	dispositivo di riferimento