

CF_FSNN — Studio di quantizzazione della rete spiking Donatello

Caratterizzazione del compromesso di quantizzazione fixed-point del core spiking per il car-following (Donatello): sicurezza del comportamento in anello chiuso e costo hardware su Zynq-7020, al variare dei bit frazionari del calcolo neurale.

Livello di fedeltà: il car-following è da simulazione in anello chiuso provata bit-vicina al motore di riferimento; risorse, potenza e frequenza sono stime Vivado post-implementazione (out-of-context), non misura su silicio.

Fonte dei numeri: matlab/Quantization_Study/{cl_sweep, res_sweep, acc_sweep, sev_sweep, mp_sens, mp_finalists, mp_res}.tsv per la rete;

matlab/Quantization_Study_IIDM/{qzi_cl_sweep, qzi_acc_sweep, qzi_sev_sweep, qzi_res}.tsv per il controllore IIDM (Sezione 9). Tutti prodotti dagli script dello studio; nessun numero è scritto a mano nel testo.

Campione: Donatello, il forward deployato del blocco Donatello_Tier. Dataset di prova: 99 traiettorie su 9 scenari canonici, di cui 33 con evento di cut-in.

Sommario

1. Sintesi	3
2. Scopo e metodo	4
3. Cosa quantizza nfrac	5
4. Sicurezza del car-following	6
5. Fedeltà dei parametri e il ginocchio	8
6. Costo hardware	9
7. Livelli utili e menu nel blocco	11
8. Quantizzazione per-campo (mixed-precision)	12
9. Il controllore IIDM: studio specchiato	15
10. Limiti residui	17
10. Riferimenti	18

1. Sintesi

La rete spiking che stima i cinque parametri del controllore di car-following opera in virgola fissa. Il numero di bit frazionari del suo calcolo interno, indicato nel seguito con n_{frac} , governa insieme l'accuratezza e il costo su silicio: più bit danno più precisione ma occupano più area e dissipano più potenza. Questo studio ne caratterizza il compromesso su tre fronti — la sicurezza del comportamento in strada, la fedeltà dei parametri stimati e l'occupazione hardware — spingendo la quantizzazione fino al limite estremo di due soli bit frazionari.

Il risultato centrale è che la sicurezza del car-following resta invariata fino a due bit frazionari. Su 99 traiettorie che comprendono 33 eventi di discontinuità del gap (cut-in, dove un veicolo si inserisce a distanza ridotta, e cut-out, dove il leader esce) e frenate del leader alla decelerazione fisica massima, la rete quantizzata non provoca alcuna collisione aggiuntiva rispetto a un controllore a conoscenza perfetta, a qualunque profondità di bit. Le sole 3 collisioni presenti sono fisicamente inevitabili, e la loro severità non cresce riducendo i bit.

Il costo hardware scende con i bit, ma in modo più sottile di quanto una lettura ingenua suggerirebbe. I registri diminuiscono in modo pulito, del 51% passando da tredici a due bit; i blocchi aritmetici calano a gradino; le celle logiche seguono invece un andamento non monotono, governato dal confine di inferenza fra blocchi aritmetici dedicati e logica combinatoria. La potenza resta pressoché costante — scende di appena l'1.8% da tredici a due bit — perché su questo dispositivo domina la dispersione statica. La frequenza massima è un margine amplissimo a ogni livello.

Ne discende la conclusione operativa: il fattore che limita la scelta dei bit non è l'hardware né la sicurezza, bensì la fedeltà dei parametri stimati. La quantizzazione sposta i parametri interni pur preservando il controllo — un comportamento da equilibri interni della rete probabilistica — e il ginocchio di quella fedeltà cade attorno a quattro-cinque bit. I quattro livelli utili che ne risultano sono stati resi selezionabili come menu nel blocco di deploy.

Un'analisi complementare, campo per campo, raffina il quadro: dei sei tipi in virgola fissa del core, due — gli accumulatori d'ingresso e i pesi — sono sovradimensionati e riducibili a quattro bit senza alcuna perdita, mentre gli altri quattro fissano la precisione. È una conferma indipendente che il limite è la fedeltà, non l'hardware; i sei bit per campo sono esposti nel blocco come Modalità Avanzata (Sezione 8).

2. Scopo e metodo

Lo studio di trade-off a monte aveva stabilito che, essendo la frequenza massima un margine enorme, il criterio di progetto rilevante è l'area — lasciare spazio ad altri blocchi sullo stesso dispositivo. La quantizzazione attacca proprio quella leva: meno bit frazionari significano meno logica e meno potenza dinamica, al costo di accuratezza. La domanda che lo studio risolve è fin dove sia lecito spingersi, e cosa fissi davvero il limite.

La valutazione poggia su tre scelte metodologiche, ciascuna volta a evitare una conclusione credibile ma falsa. La prima è il dataset di prova esaustivo. Un insieme di sole traiettorie di inseguimento dolce non mette mai il controllore in difficoltà, e vi si sopravvive banalmente anche molto degradati; perciò la prova usa i 9 scenari canonici del progetto — inseguimento, stop-and-go, frenata forte, cut-in, sinusoidale, e quattro scenari di coda fra cui il cut-in aggressivo e la frenata di emergenza — replicati su più estrazioni di parametri, per un totale di 99 traiettorie di cui 33 con un vero evento di cut-in, modellato come una discontinuità del gap.

La seconda scelta è l'anello chiuso fedele. La sicurezza si misura simulando l'ego guidato dalla rete quantizzata contro il profilo del leader, con il gap tracciato senza clamp inferiore, così che una collisione sia rilevabile; l'evento di cut-in vi è iniettato come teletrasporto del gap. Questo anello riproduce il motore canonico del progetto: sui nove scenari, l'oracolo simulato in MATLAB e la funzione di riferimento in Python coincidono passo per passo entro $2.2e-06$ m sul gap, con i medesimi verdeti di collisione. La misura di comportamento è dunque quella vera, non quella di un anello che nasconde le collisioni dietro un clamp.

La terza scelta è la linea di base oracolo per traiettoria. Prima dello sweep, un controllore a parametri veri (l'oracolo) percorre tutte le traiettorie e marca quali collisioni siano fisicamente evitabili. Per la rete a ciascun nfrac, allora, contano solo le collisioni su traiettorie che l'oracolo evita: quelle, e solo quelle, sono il costo reale della quantizzazione, separato da ciò che nessun controllore potrebbe evitare. Sul dataset, 3 traiettorie su 99 sono inevitabili già per l'oracolo.

3. Cosa quantizza nfrac

La quantizzazione agisce sul calcolo neurale interno, non sull'ingresso-uscita del blocco. Il parametro nfrac fissa il numero di bit frazionari dei tipi in virgola fissa del core spiking, lasciando invariati i bit interi — dunque il campo di rappresentazione non cambia, cambia solo la risoluzione. I segnali interessati sono il potenziale di membrana del neurone, la soglia adattiva, gli accumulatori della corrente sinaptica, i pesi a potenza di due e l'uscita grezza del readout, oltre all'ingresso normalizzato, che eredita il tipo del potenziale di membrana.

$$V \sim Q5.n, \text{ fatigue} \sim Q3.n, \text{ acc} \sim Q5.n, \text{ accw} \sim Q8.(n+4), \text{ raw} \sim Q7.n, w \sim Q2.n$$

Equazione 3.1 — i tipi del core al variare di $n = \text{nfrac}$ (notazione $Qm.n$: m bit interi, n bit frazionari). V = potenziale di membrana; fatigue = soglia adattiva; acc/accw = accumulatori (accw più largo per gli scorrimenti esatti); raw = uscita del readout; w = pesi. I bit interi sono fissi; solo n varia. Fonte: `matlab/snn_types.m`.

Restano fuori dalla quantizzazione, per costruzione, due elementi. Gli ingressi fisici — distanza, velocità dell'ego, velocità relativa e velocità del leader — arrivano a piena risoluzione: la loro quantizzazione sul canale di comunicazione è un asse separato, estraneo a questo studio. E il decodificatore che trasforma l'uscita grezza nei cinque parametri: la sua aritmetica e le sue costanti sono fisse a tredici bit frazionari, indipendenti da nfrac. L'uscita grezza, calcolata alla precisione nfrac, vi entra e viene portata a tredici bit senza perdita ulteriore. In una frase, nfrac è la profondità di bit del calcolo neurale — stato, pesi, accumulatori, readout — non dell'ingresso-uscita né della ricostruzione finale dei parametri.

4. Sicurezza del car-following

La misura di sicurezza confronta, a ogni nfrac, le collisioni della rete con la linea di base oracolo. Il conteggio delle collisioni aggiuntive — quelle su traiettorie che l'oracolo evita — è zero a ogni livello, fino a due bit frazionari. Le sole 3 collisioni presenti a ogni nfrac sono le stesse dell'oracolo: scenari di cut-in aggressivo in cui la decelerazione richiesta supera il limite fisico del veicolo, dunque inevitabili per qualunque controllore. La rete quantizzata eguaglia il controllore a conoscenza perfetta sull'evitamento a ogni profondità di bit.




Figura 4.1 — Sicurezza car-following al variare di nfrac. La curva (asse sinistro) è l'errore normalizzato dei parametri rispetto a piena precisione; le barre (asse destro) sono le collisioni aggiuntive rispetto all'oracolo, nulle a ogni livello. Fonte: cl_sweep.tsv.

Anche i margini di sicurezza istantanei confermano l'invarianza. Il passaggio più stretto su tutte le traiettorie evitabili è di circa 0.22 m nel caso peggiore, non si annulla mai e non peggiora riducendo i bit; il margine di evitabilità e la decelerazione richiesta critica oscillano con la geometria degli scenari, non con nfrac. In altre parole, l'involuppo di sicurezza è fissato dai casi più duri del dataset, e la rete lo percorre allo stesso modo a tredici come a due bit.

$$\text{brake_margin} = s - \frac{\max(0, \Delta v)^2}{2B_{\max}}, \quad \text{DRAC} = \frac{\Delta v^2}{2s}$$

Equazione 4.1 — margine di frenata e decelerazione richiesta (DRAC). s = gap (m); Δv = velocità di avvicinamento (m/s); $B_{\max} = 9 \text{ m/s}^2$ = decelerazione fisica massima. Un margine di frenata negativo segnala che, se il leader frenasse al massimo in quell'istante, la collisione sarebbe inevitabile. Fonte: matlab/Quantization_Study/qz_safety_metrics.m (porta di utils/closed_loop_eval.py).

Resta da chiudere il caso delle collisioni inevitabili: dove nessun controllore evita l'urto, la quantizzazione lo rende più violento? La severità, misurata come velocità relativa al contatto, è piatta su tutti i livelli: il suo massimo è 7.65 m/s, appena sotto la severità dell'oracolo (7.69 m/s), da tredici fino a due bit frazionari. Dove la collisione è comunque inevitabile, la rete a due bit non urta né più né meno di quella a tredici bit o del controllore a conoscenza perfetta.




Figura 4.2 — Severità (velocità relativa al contatto) sulle 3 traiettorie inevitabili, al variare di nfrac. La linea tratteggiata è la severità dell'oracolo. La curva della rete è piatta e le resta appena sotto. Fonte: sev_sweep.tsv.

5. Fedeltà dei parametri e il ginocchio

Se la sicurezza non si degrada, cosa lo fa? La fedeltà dei parametri stimati. L'errore normalizzato medio dei cinque parametri (NRMSE) rispetto a piena precisione cresce in modo liscio al calare dei bit, con un ginocchio attorno a quattro-cinque bit frazionari: è pressoché costante sopra — passa da 0.089 a otto bit a 0.097 a cinque — e poi accelera sotto, raddoppiando quasi a ogni bit, fino a 0.201 a tre e 0.327 a due. La rete probabilistica riorganizza i propri parametri sotto quantizzazione, ma la legge di controllo e la retroazione ne assorbono lo scarto: è questo che spiega la sicurezza invariante a fronte di parametri visibilmente diversi.

$$\text{NRMSE}_p = \frac{\sqrt{\langle (p^{(n)} - p^{(13)})^2 \rangle}}{\max p^{(13)} - \min p^{(13)}}$$

Equazione 5.1 — errore normalizzato del parametro p a n bit, rispetto al riferimento a tredici bit; la media è sul dataset e la normalizzazione è sull'escursione del parametro nel riferimento (adimensionale). Fonte: `matlab/Quantization_Study/qz_cl_validate.m`.

Questa vista in anello chiuso capovolge quella open-loop. Misurando lo scarto massimo dei parametri sul solo forward, senza retroazione, la rete appare sensibile già a bit medi: il parametro peggiore devia di mezzo-un'unità fisica ben prima del limite. Ma quel massimo peggiore è una vista pessimista; il comportamento in strada, che è ciò che conta, la smentisce. La stessa quantizzazione che sembra rovinosa sui numeri grezzi lascia il controllo sicuro fino a due bit.




Figura 5.1 — Accuratezza open-loop worst-case (massimo scarto assoluto sui cinque parametri, in unità fisiche) al variare di n_{frac} . Vista pessimista che il comportamento in anello chiuso ridimensiona. Fonte: `acc_sweep.tsv`.

6. Costo hardware

Il costo su silicio è stato misurato sintetizzando il forward a ciascun nfrac su Vivado, in modalità out-of-context su una configurazione di pipeline di riferimento, con lo stesso vincolo di clock di deploy (125 ns, io-timed) per tutti i livelli, così che il confronto sia omogeneo. Il risparmio d'area non è un semplice andamento monotono: è governato dal confine di inferenza fra blocchi aritmetici dedicati e logica combinatoria.




Figura 6.1 — Risorse al variare di nfrac. A sinistra celle logiche e registri; a destra i blocchi aritmetici. I registri calano in modo pulito, i blocchi aritmetici a gradino sotto cinque bit, le celle logiche in modo non monotono per il travaso dai blocchi aritmetici. Fonte: res_sweep.tsv.

I registri sono la metrica pulita: monotoni, calano del 51% da tredici a due bit. I blocchi aritmetici scendono a gradino — restano stabili sopra i cinque bit, poi crollano sotto, quando le moltiplicazioni più strette smettono di occupare un blocco dedicato. Proprio quel travaso rende le celle logiche non monotone: calano da tredici a cinque bit (21% a cinque bit), poi risalgono a quattro — dove le moltiplicazioni uscite dai blocchi diventano logica — e infine scendono di nuovo a due-tre bit, dove quella stessa logica si restringe. Il livello a cinque bit usa così meno celle logiche del livello a quattro ed è anche più fedele; il livello a quattro conserva però meno blocchi aritmetici, un vantaggio che pesa solo se il DSP è la risorsa scarsa — non il caso qui. Nel menu prevale perciò il cinque.

La potenza non partecipa a questo compromesso: è piatta — scende di appena l'1.8% da tredici a due bit. La ragione è che su questo dispositivo la dispersione statica vale il 93% della potenza totale; la quota dinamica della logica, la sola che scala con i bit, è troppo piccola per spostare il totale. La quantizzazione, su questo silicio, non fa risparmiare potenza. Vi è però un corollario: la rete è idle per costruzione per oltre il 99,9% del tempo, dunque su un dispositivo dove la potenza dinamica fosse il collo di bottiglia il risparmio si materializzerebbe; qui non lo fa perché domina la statica del dispositivo, non un difetto della rete.




Figura 6.2 — Potenza al variare di nfrac: totale, statica del dispositivo e dinamica della logica. La statica domina e il totale è piatto. Fonte: res_sweep.tsv.

La frequenza massima, infine, è un margine e non una proprietà del progetto a questo vincolo: oscilla fra circa 51 e 60 MHz al punto di deploy, ma il tool non spinge (lo slack è ampiamente positivo). Poiché ogni inferenza richiede alcune centinaia di cicli, il passo di controllo di 100 ms si accontenta di un clock dell'ordine di qualche kilohertz: ogni livello vi resta migliaia di volte sopra. Non è quindi una leva di scelta dei bit.

7. Livelli utili e menu nel blocco

Incrociando i tre fronti — sicurezza, fedeltà, costo — la lettura è netta. La sicurezza regge fino a due bit e non pone limite; la potenza è piatta; il risparmio d'area è modesto e non monotono. Ciò che detta la scelta dei bit è la fedeltà dei parametri. Ne emergono quattro livelli utili.

Livello (nfrac)	Uso	NRMSE parametri	Risorse vs 13 bit	Collisioni extra
13	piena precisione (riferimento)	0.000	—	0
8	conservativo	0.089	-13% celle, -18% registri	0
5	compromesso area/fedeltà	0.097	-21% celle, -28% registri	0
2	aggressivo (solo sicurezza)	0.327	-39% celle, -51% registri	0

Questi quattro livelli sono stati resi selezionabili nel blocco di deploy Donatello_Tier, come secondo menu accanto a quello del profilo di pipeline. La rete a ciascun livello è una variante distinta con i tipi in virgola fissa già fissati a quel nfrac; alla piena precisione la variante coincide bit per bit con il forward storico, come atteso da una sostituzione che a tredici bit è un'operazione neutra.

Nota. Nota realizzativa: un menu che pilotasse la profondità di bit come parametro vivo, rigenerando i tipi a runtime, non si è potuto ottenere, perché un parametro di contenitore non raggiunge una funzione annidata dentro un sotto-sistema a varianti. Le quattro varianti discrete, coi tipi già fissati, aggirano il vincolo e sono la soluzione robusta adottata.

8. Quantizzazione per-campo (mixed-precision)

Le sezioni precedenti abbassano un unico nfrac per l'intero core, e ne misurano il costo con due criteri: la sicurezza — zero collisioni evitabili in più rispetto all'oracolo (Sezione 4) — e la fedeltà dei parametri, l'NRMSE (Sezione 5). Questa sezione pone una domanda complementare con gli stessi due criteri: i sei tipi del core valgono tutti i loro bit allo stesso modo? Ciascuno riceve un nfrac indipendente, e si misura fin dove ognuno può scendere da solo, tenendo gli altri cinque a tredici.

Sul fronte della sicurezza la risposta è coerente con la Sezione 4, ed è netta: ogni campo, da solo, tollera la riduzione fino a un solo bit senza alcuna collisione aggiuntiva. Su tutte le 78 configurazioni per campo — sei campi per tredici livelli — le collisioni extra restano zero. Come per lo studio uniforme, la sicurezza non è il limite: non è lei a dire quanti bit servano.




Figura 8.1 — Fedeltà per campo (NRMSE dei parametri rispetto alla piena precisione) quando si abbassa il nfrac di un solo campo, tenendo gli altri cinque a tredici. acc e w restano esattamente a zero — riduzione senza perdita — fino a quattro bit; V, fatigue, accw e raw degradano già al primo bit tolto. In tutte le configurazioni le collisioni extra sono zero. Fonte: mp_sens.tsv.

È la fedeltà a separare i sei campi, e lo fa in modo netto. Due di essi — l'accumulatore d'ingresso e i pesi — mantengono NRMSE esattamente a zero fino a quattro bit: la loro riduzione non è un compromesso ma senza perdita, l'uscita bit-identica alla piena precisione. Gli altri quattro degradano al primo bit tolto. È un risultato di natura diversa da quello dello studio uniforme: non "quanta perdita è tollerabile", ma "quali campi non portano informazione da togliere".

Campo	Ruolo	Floor senza perdita (nfrac)	Sicurezza
V	potenziale di membrana	13	fino a 1 bit
fatigue	soglia adattiva	13	fino a 1 bit
acc	accumulatore d'ingresso	4	fino a 1 bit
accw	accumulatore largo	13	fino a 1 bit
raw	uscita del readout	13	fino a 1 bit
w	pesi a potenza di due	4	fino a 1 bit

Il "floor senza perdita" è il nfrac più basso a cui l'uscita resta bit-identica alla piena precisione. La sicurezza — colonna a fianco — regge invece fino a un bit per ogni campo, esattamente come nello studio uniforme; le due colonne dicono cose diverse, e solo la fedeltà distingue i campi.

Il meccanismo è verificato, non ipotizzato. Ispezionando i pesi del campione, tutte le matrici (fc, ricorrenti, readout) sono potenze di due con modulo minimo esattamente 2^{-4} . Quindi 4 bit frazionari rappresentano ogni peso in modo esatto (a tre bit il peso 2^{-4} sparisce, e la rete si rompe); e l'accumulatore d'ingresso, che somma pesi-po2 per spike interi, vive su una griglia da 2^{-4} e serve anch'esso a quattro bit. Gli altri quattro campi portano grandezze continue — pilotate da quantità non-po2 come la soglia e i parametri del decode — e usano tutta la loro precisione: ogni bit tolto sposta subito i parametri.

Ne segue la relazione con lo studio uniforme. La config senza perdita è [13 13 4 13 13 4] — soli acc e w a quattro bit — con NRMSE e scarto del gap nulli (verifica congiunta): è bit-identica alla piena precisione. La riduzione *con perdita* dello studio uniforme — il ginocchio attorno a quattro-cinque bit — è dunque guidata dai quattro campi continui; la precisione mista isola e rimuove la parte senza perdita (acc e w) che quella uniforme, muovendo tutti i campi insieme, non può separare. In questo senso i due studi sono coerenti e complementari: l'uniforme misura il compromesso di fedeltà, il per-campo individua ciò che è ridondante a monte del compromesso.




Figura 8.2 — Risorse dei finalisti a 125 ns io-timed, in percentuale del full-precision (etichette = valori assoluti). La finale taglia i blocchi aritmetici e i registri ma alza le celle logiche; la uniforme a quattro bit (con perdita, cioè non bit-identica, solo riferimento hardware) mostra il soffitto. Fonte: mp_res.tsv.

Config	LUT	FF	DSP	slack WNS (ns)	P dinamica (mW)
full 13x6	4628	3474	52	106	8
finale [13,13,4,13,13,4]	5203	3045	36	106	10
uniform 4x6 (con perdita)	4856	2381	31	106	8

In hardware, però, il pranzo comportamentalmente gratis non è un risparmio pulito. La finale taglia i blocchi aritmetici del 31% e i registri del 12%, ma alza le celle logiche del 12%: è lo stesso confine fra blocchi dedicati e logica già visto nella Sezione 6 — le moltiplicazioni strette di acc e w escono dai blocchi e diventano celle. La potenza non aiuta: la dinamica passa da 8 a 10 mW (sale, per le celle in più), e a questa scala di pochi milliwatt stimati la differenza è entro la risoluzione. Il margine di timing è enorme — lo slack (worst negative slack, WNS) è di circa 106 ns sul vincolo di deploy da 125 ns — dunque la frequenza non è il collo. La lettura onesta: i bit sovra-dimensionati di acc e w sono liberi da togliere nel comportamento, ma su questo Zynq DSP-ricco e static-dominato il taglio ribilancia blocchi verso celle senza vero guadagno d'area né di potenza. Il valore dell'analisi per-campo è diagnostico — dice quali campi portano informazione e quali no — e conferma, per via indipendente, il verdetto dello studio uniforme: il collo dei bit è la fedeltà, non l'hardware.

I sei $nfrac$ per campo sono esposti nel blocco di deploy come Modalità Avanzata: una casella di spunta accanto ai menu di base sblocca sei cursori (uno per campo, da 1 a 13). Come per il menu di base, la configurazione è realizzata da varianti coi tipi già fissati — il generatore del blocco cuoce la variante avanzata ai valori scelti — perché un blocco legato alla libreria non può rigenerare la propria logica a runtime. Alla piena precisione la variante avanzata coincide bit per bit con quella di base.

9. Il controllore IIDM: studio specchiato

La rete è meta' del sistema di car-following; l'altra meta' è il controllore ACC-IIDM che trasforma i cinque parametri stimati in accelerazione. Questa sezione ne caratterizza la quantizzazione con lo stesso metodo applicato alla rete, a ruoli invertiti: la rete è congelata a piena precisione e a variare è ora il nfrac dell'IIDM. L'anello chiuso e le metriche sono le stesse; ciò che nella rete si misurava sui cinque parametri, qui si misura sull'accelerazione — l'uscita del controllore.

La sicurezza ha un floor diverso da quello della rete. Fino a cinque bit frazionari il controllore quantizzato non provoca alcuna collisione aggiuntiva rispetto all'oracolo; a due bit, invece, il car-following si rompe — 49 collisioni evitabili mancate, con passaggi a gap negativo. È una differenza sostanziale rispetto alla rete, sicura fino a due bit: l'IIDM è il pezzo fragile alla precisione estrema, e il suo floor di sicurezza cade fra cinque e due bit.




Figura 9.1 — Controllore IIDM al variare del suo nfrac. La curva (asse sinistro) è l'errore normalizzato dell'accelerazione open-loop rispetto al riferimento in doppia precisione; le barre (asse destro) sono le collisioni aggiuntive rispetto all'oracolo — nulle a 13/8/5, 49 a due bit. Fonte: qzi_cl_sweep.tsv, qzi_acc_sweep.tsv.

La fedeltà dell'accelerazione degrada in modo liscio e monotono al scendere dei bit: l'errore normalizzato open-loop passa da 0.0008 a tredici bit a 0.045 a due, e lo scarto worst-case sale da 0.19 a 5.54 m/s². Il valore a otto bit — 0.81 m/s² di scarto massimo — coincide col budget di quantizzazione già stabilito per l'IIDM (l'errore in accelerazione che la quantizzazione della rete aveva già introdotto a monte): otto bit è il punto in cui l'IIDM smette di essere trascurabile rispetto alla rete. È lo sweet-spot.

La severità conferma il quadro della rete: sulle traiettorie fisicamente inevitabili, l'impatto al contatto del controllore quantizzato resta pari a quello dell'oracolo a ogni nfrac — la quantizzazione dell'IIDM non rende i crash inevitabili più violenti. Fonte: qzi_sev_sweep.tsv.

Il blocco di deploy: architettura veloce, precisione fissa. A differenza della rete, il controllore ottimizzato non è parametrico in precisione: divisore e radice quadrata *digit-recurrence* hanno larghezze di bit cablate per otto bit frazionari, e cambiare nfrac romperebbe quelle ricorrenze. Perciò il blocco dell'IIDM è a precisione fissa a otto bit — proprio lo sweet-spot individuato sopra — senza menu.

Quell'implementazione è il frutto di una campagna di ottimizzazione a 17 round, tutti bit-esatti, che ha portato il controllore da 15.7 MHz (divisione combinatoria, baseline) a 77.9 MHz (+397%): divisore e radice sequenzializzati (uno-due bit per ciclo, hardware più piccolo del combinatorio srotolato) e le catene lunghe della legge IIDM distribuite su più stadi di registro. Il blocco standalone (senza la rete, i cinque parametri in ingresso) è derivato da quell'architettura e sintetizza a 75.6 MHz

allo stesso collo critico (l'accelerazione IIDM); la differenza di ~3% dal controllore completo è il contesto standalone — i parametri arrivano dagli ingressi invece che dal decodificatore pipelinato della rete. Come per la rete, questa frequenza è margine: un passo di controllo da 0,1 s dura 800.000 clock a 8 MHz, contro i ~150 di una inferenza.

Variante IIDM	Fmax (MHz)	LUT	FF	DSP	collo (liv.)
baseline R0 (combinatorio)	15.7	8230	3183	69	204
controllore R17 (SNN+IIDM)	77.9	8387	4069	68	14
IIDM standalone R17 (blocco)	75.6	3670	1173	17	15

Il blocco è provato bit-esatto rispetto al modello di riferimento in doppia precisione (errore massimo nullo in streaming) e genera VHDL in modo self-contained. Resta componibile con qualunque stimatore: riceve i cinque parametri e restituisce l'accelerazione. In sintesi, il sistema car-following completo — stima (rete) e legge di controllo (IIDM) — è ora caratterizzato in quantizzazione su entrambe le meta'.

10. Limiti residui

Vanno dichiarati quattro limiti. Le curve di risorse, potenza e frequenza sono stime Vivado post-implementazione con vincolo di deploy, non misure su silicio; il loro andamento relativo fra i livelli è affidabile, i valori assoluti attendono la misura su scheda. La caratterizzazione hardware è inoltre condotta su una configurazione di pipeline di riferimento: il ginocchio e le curve di risorsa e potenza sono robusti al profilo scelto — la quantizzazione tocca la logica del core, comune ai profili — mentre il solo valore assoluto di frequenza massima è specifico di quella configurazione. Lo studio varia esclusivamente i bit del core: la quantizzazione degli ingressi è un asse separato, fuori campo. Infine, la caratterizzazione hardware della precisione mista (Sezione 8) poggia su un insieme ridotto di tre configurazioni sintetizzate, non su uno sweep completo per campo — che richiederebbe ore di sintesi; le curve di sensibilità sono isolate, un campo per volta, e la verifica congiunta delle interazioni è svolta sulla sola configurazione finale.

10. Riferimenti

Riferimento	Tema
Treiber, M., Kesting, A. (2013). Traffic Flow Dynamics. Springer (IIDM/ACC, cap. 11-12).	Modello di car-following
Kesting, A., Treiber, M., Helbing, D. (2010). Enhanced IDM (ACC/CAH). Phil. Trans. R. Soc. A 368, 4585-4605.	Legge di controllo
Minderhoud, M. M., Bovy, P. H. L. (2001). Extended time-to-collision safety measures. Accid. Anal. Prev. 33(1), 89-97.	Metriche di sicurezza (TTC/TET/TIT)
Archer, J. (2005). Traffic conflict techniques and micro-simulation (DRAC critico ~ 3.35 m/s ²). KTH, Stockholm.	DRAC e conflitti
AMD/Xilinx. Zynq-7000 SoC Data Sheet (DS187); Vivado Design Suite 2026.1.	Dispositivo e sintesi